Syayid Al Aziz

Repository Tugas Pencarian dan Penambangan Web

To blah, blah, and blah.

Table of contents

Tentang

Berikut merupakan repository yang saya buat berisikan tugas pada mata kuliah Pencarian dan Penambangan Web, dalam repository ini berisikan topic modeling pada tugas akhir Universitas Trunojoyo Madura dan ringkasan berita pada yang datanya diambil pada website CNN Indonesia, tidak hanya itu terdapat juga beberapa langkah-langkah mulai dari pengambilan data (crawling) dan tahapan utama hingga selesai dari kedua pekerjaan ini yaitu topic modeling dan ringkasan dokumen

0

Crawl PTA Trunojoyo

```
!pip install requests
!pip install beautifulsoup4
import requests
from bs4 import BeautifulSoup
import pandas as pd
```

```
Requirement already satisfied: requests in /usr/local/lib/python3.10/dist-packages (2.31.0)
Requirement already satisfied: charset-normalizer<4,>=2 in /usr/local/lib/python3.10/dist-packages (
Requirement already satisfied: idna<4,>=2.5 in /usr/local/lib/python3.10/dist-packages (from requests
Requirement already satisfied: urllib3<3,>=1.21.1 in /usr/local/lib/python3.10/dist-packages (from re
Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.10/dist-packages (from re
Requirement already satisfied: beautifulsoup4 in /usr/local/lib/python3.10/dist-packages (4.11.2)
Requirement already satisfied: soupsieve>1.2 in /usr/local/lib/python3.10/dist-packages (from beautif
```

0

Crawling Data

```
def ptaa():
    data = {"penulis": [], "judul": [], "pembimbing_pertama": [], "pembimbing_kedua": [], "abst

    for i in range(1, 4):
        url = "https://pta.trunojoyo.ac.id/c_search/byprod/10/{}".format(i)
        r = requests.get(url)
        request = r.content
        soup = BeautifulSoup(request, "html.parser")
        jurnals = soup.select('li[data-cat="#luxury"]')

        for jurnal in jurnals:
            response = requests.get(jurnal.select_one('a.gray.button')['href'])
            soup1 = BeautifulSoup(response.content, "html.parser")

            isi = soup1.select_one('div#content_journal')

            judul = isi.select_one('a.title').text

            penulis = isi.select_one('span:contains("Penulis")').text.split(' : ')[1]
            # penulis = penulis_span.find_next('span').text.split(' : ')

            pembimbing_pertama = isi.select_one('span:contains("Dosen Pembimbing I")').text.spl
            # pembimbing_pertama = pembimbing_pertama_span.find_next('span')

            pembimbing_kedua = isi.select_one('span:contains("Dosen Pembimbing II")').text.spli
            # pembimbing_kedua = pembimbing_kedua_span.find_next('span')

            abstrak = isi.select_one('p[align="justify"]').text
            if abstrak == '':
              abstrak = ' '.join(isi.find('p').findNext('p').stripped_strings).capitalize()

            data["penulis"].append(penulis)
            data["judul"].append(judul)
            data["pembimbing_pertama"].append(pembimbing_pertama)
```

```
            data["pembimbing_kedua"].append(pembimbing_kedua)
            data["abstrak"].append(abstrak)

    df = pd.DataFrame(data)
    df.to_csv("pta.csv", index=False)

    return df
```

```
ptaa()
```

	penulis	judul
0	A.Ubaidillah S.Kom	PERANCANGAN DAN IMPLEMENTASI SISTEM DATABASE \...
1	M. Basith Ardianto,	APLIKASI KONTROL DAN MONITORING JARINGAN KOMPU...
2	Akhmad Suyandi, S.Kom	RANCANG BANGUN APLIKASI PROXY SERVER UNTUK\r\n...
3	Heri Supriyanto	SISTEM PENDUKUNG KEPUTUSAN OPTIMASI PENJADWALA...
4	Septian Rahman Hakim	SISTEM AUGMENTED REALITY ANIMASI BENDA BERGERA...
5	Adi Chandra Laksono	Gerak Pekerja Pada Game Real Time Strategy Men...
6	NURRACHMAT	RANCANG BANGUN GAME PERAWATAN SAPI KARAPAN MEN...
7	Muhammad Choirur Rozi	EKSTRAKSI FITUR BERBASIS TWO DIMENSIONAL LINEA...
8	M Khoiril Anwar	IMPLEMENTASI ALGORITMA PRIM DAN DEPTH FIRST ...
9	MALIKUL HAMZAH	Perancangan Sistem Informasi Badan Kepegawaian...
10	Norman	PEMANFAATAN TOGAF ADM UNTUK PERANCANGAN SISTEM...
11	Robiatul Adawiyah, S.Kom	APLIKASI METODE FUZZY ANALYTIC NETWORK PROCESS...
12	Desy Mariana S. Kom	SISTEM PENDUKUNG KEPUTUSAN REKOMENDASI MENU DI...
13	Lia Fransiska	RANCANG BANGUN APLIKASI PEMILIHAN TEKNIK REKAY...
14	Erwina Safitri	DETEKSI COREPOINT SIDIK JARI MENGGUNAKAN METOD...

0

Topic Modeling PTA

Aplikasi untuk topic modelling Topic Classification[1]

[1] https://syayidalaziz-pta-topic-classification.hf.space/

0

Instalisasi

```
!pip install nltk
!pip install Sastrawi
!pip install gensim
```

```
Requirement already satisfied: nltk in /usr/local/lib/python3.10/dist-packages (3.8.1)
Requirement already satisfied: click in /usr/local/lib/python3.10/dist-packages (from nltk) (8.1.7)
Requirement already satisfied: joblib in /usr/local/lib/python3.10/dist-packages (from nltk) (1.3.2)
Requirement already satisfied: regex>=2021.8.3 in /usr/local/lib/python3.10/dist-packages (from nltk)
Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-packages (from nltk) (4.66.1)
Requirement already satisfied: Sastrawi in /usr/local/lib/python3.10/dist-packages (1.0.1)
Requirement already satisfied: gensim in /usr/local/lib/python3.10/dist-packages (4.3.2)
Requirement already satisfied: numpy>=1.18.5 in /usr/local/lib/python3.10/dist-packages (from gensim)
Requirement already satisfied: scipy>=1.7.0 in /usr/local/lib/python3.10/dist-packages (from gensim)
Requirement already satisfied: smart-open>=1.8.1 in /usr/local/lib/python3.10/dist-packages (from ge
```

```
import pandas as pd
import nltk
import gensim
import re
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from nltk.corpus import stopwords
from gensim import corpora
from gensim.models import LdaModel
from gensim.models.coherencemodel import CoherenceModel
from Sastrawi.Stemmer.StemmerFactory import StemmerFactory
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.feature_extraction.text import TfidfVectorizer, CountVectorizer
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import GridSearchCV
```

```
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import ConfusionMatrixDisplay, confusion_matrix, accuracy_score, precision
import joblib
```

```
nltk.download("punkt")
nltk.download("stopwords")
```

```
[nltk_data] Downloading package punkt to /root/nltk_data...
[nltk_data]   Package punkt is already up-to-date!
[nltk_data] Downloading package stopwords to /root/nltk_data...
[nltk_data]   Package stopwords is already up-to-date!
```

```
True
```

0

Data

```
from google.colab import drive
drive.mount('/content/drive')

csv_path = '/content/drive/My Drive/Task/Pencarian dan Penambangan Web/Tugas 1/data/pta-teknik-
df = pd.read_csv(csv_path)
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/dr
```

```
dat = df.dropna(subset=['abstrak'])
```

```
dat
```

	penulis	judul
0	A.Ubaidillah S.Kom	PERANCANGAN DAN IMPLEMENTASI SISTEM DATABASE T...
1	M. Basith Ardianto,	APLIKASI KONTROL DAN MONITORING JARINGAN KOMPU...
2	Akhmad Suyandi, S.Kom	RANCANG BANGUN APLIKASI PROXY SERVER UNTUK\nEN...
3	Heri Supriyanto	SISTEM PENDUKUNG KEPUTUSAN OPTIMASI PENJADWALA...
4	Septian Rahman Hakim	SISTEM AUGMENTED REALITY ANIMASI BENDA BERGERA...
...	...	...
826	Rachmad Agung Pambudi	PENERAPAN ALGORITMA LONG-SHORT TERM MEMORY UNT...
827	Nadila Hidayanti	SISTEM PENCARIAN TEKS AL-QURAN TERJEMAHAN BERB...
828	Afni Sakinah	KLASIFIKASI KOMPLEKSITAS VISUAL CITRA SAMPAH M...
829	Friska Fatmawatiningrum	IDENTIFIKASI BINER ATRIBUT PEJALAN KAKI MENGGU...
830	Dian Wibowo	DETEKSI OBJEK MANUSIA BERBASIS ONE STAGE DETEC...

```
count_komputasi = (dat['label-topic'] == 'komputasi').sum()
count_rpl = (dat['label-topic'] == 'rpl').sum()

print('komputasi = ', count_komputasi, 'rpl = ', count_rpl)
```

```
komputasi =  547 rpl =  277
```

0

Preprocessing Data

Text preprocessing merupakan tahapan dalam Natural Language Processing (NLP) yang bertujuan untuk membersihkan dan menyiapkan teks mentah menjadi data siap digunakan pada proses yang lebih lanjut. Text preprocessing ini menjadi sangat krusial karena membantu mengatasi berbagai masalah seperti data berantakan, tanda baca yang berlebihan, serta variasi dalam bentuk kata

```
dat=df.astype(str)
dat["abstrak"] = dat["abstrak"].apply(lambda x: x.lower())

abstrak_column = dat["abstrak"]
abstrak_column
```

```
0      sistem  informasi  akademik  (siakad) merupaka...
1      berjalannya koneksi jaringan komputer dengan l...
2      web server adalah sebuah perangkat lunak serve...
3      penjadwalan  kuliah  di  perguruan  tinggi  me...
4      seiring perkembangan teknologi yang ada diduni...
                            ...
826    investasi saham selama ini memiliki resiko ker...
827    information retrieval (ir) merupakan pengambil...
828    klasifikasi citra merupakan proses pengelompok...
829    identifikasi atribut pejalan kaki merupakan sa...
830    topik deteksi objek telah menarik perhatian ya...
Name: abstrak, Length: 824, dtype: object
```

0.1 Tokenisasi

Tokenizing adalah proses yang mengubah teks berkelanjutan menjadi unit-unit yang lebih kecil dan disebut dengan token. Token ini biasanya adalah kata, frasa, atau tanda baca yang memisahkan kata-kata dalam teks, dengan ini akan memudahkan untuk melakukan analisis terhadap teks dan akan

membantu menyaring kata-kata yang tidak diinginkan pada pemrosesan teks lebih lanjut

```
def process_tokenize(text):
    text = text.split()
    return text

tokenize_abstrak = abstrak_column.apply(process_tokenize)
tokenize_abstrak

# token = pd.DataFrame(df, columns = tokenize_abstrak)
```

```
0      [sistem, informasi, akademik, (siakad), merupa...
1      [berjalannya, koneksi, jaringan, komputer, den...
2      [web, server, adalah, sebuah, perangkat, lunak...
3      [penjadwalan, kuliah, di, perguruan, tinggi, m...
4      [seiring, perkembangan, teknologi, yang, ada, ...
                             ...
826    [investasi, saham, selama, ini, memiliki, resi...
827    [information, retrieval, (ir), merupakan, peng...
828    [klasifikasi, citra, merupakan, proses, pengel...
829    [identifikasi, atribut, pejalan, kaki, merupak...
830    [topik, deteksi, objek, telah, menarik, perhat...
Name: abstrak, Length: 824, dtype: object
```

0.2 Process Punctuation

Proses punctuation ini digunakan untuk mengahapus karakter yang tidak digunakan pada teks, seperti tanda baca dan angka. Beberapa karakter ini harus dihilangkan karena karakter tersebut tidak akan mempengaruhi hasil pada saat melakukan klasifikasi topic

```
def process_punctuation(tokens):
    cleaned_tokens = [re.sub(r'[.,()&=%:-]', '', token) for token in tokens]
    cleaned_tokens = [re.sub(r'\d+', '', token) for token in cleaned_tokens]

    return cleaned_tokens

punctuation_abstrak = tokenize_abstrak.apply(process_punctuation)

# data = pd.DataFrame(df, columns=['punctuation_abstrak'])
```

```
# data
punctuation_abstrak
```

```
0      [sistem, informasi, akademik, siakad, merupaka...
1      [berjalannya, koneksi, jaringan, komputer, den...
2      [web, server, adalah, sebuah, perangkat, lunak...
3      [penjadwalan, kuliah, di, perguruan, tinggi, m...
4      [seiring, perkembangan, teknologi, yang, ada, ...
                           ...
826    [investasi, saham, selama, ini, memiliki, resi...
827    [information, retrieval, ir, merupakan, pengam...
828    [klasifikasi, citra, merupakan, proses, pengel...
829    [identifikasi, atribut, pejalan, kaki, merupak...
830    [topik, deteksi, objek, telah, menarik, perhat...
Name: abstrak, Length: 824, dtype: object
```

0.3 Stopword

Remove Stopword adalah tahap yang melibatkan penghapusan kata-kata umum yang dianggap tidak memberikan nilai signifikan dalam analisis teks. Kata-kata semacam ini disebut stop words karena mereka sering muncul dalam teks bahasa alami tanpa memberikan informasi penting tentang isi atau makna teks. Contoh kata-kata umum ini termasuk “dan”, “atau”, “di”, “dari”, “yang”,” itu”, dan sebagainya. Penghapusan stop words bertujuan untuk mengurangi ukuran teks, mempercepat pemrosesan, dan meningkatkan relevansi informasi yang diambil dari teks, sehingga hanya kata kunci yang membentuk topik yang akan diekstraksi.

```
def process_stopword_token(tokens):
    stop_words = set(stopwords.words("indonesian"))
    custom_stop_words = ['masingmasing','tiaptiap','satusatunya', 'intinya', 'seiring']
    stop_words.update(custom_stop_words)
    filtered_tokens = [token for token in tokens if token.lower() not in stop_words]
    return " ".join(filtered_tokens)

stopword_abstrak = punctuation_abstrak.apply(process_stopword_token)
stopword_abstrak
```

```
0      sistem informasi akademik siakad sistem inform...
1      berjalannya koneksi jaringan komputer lancar g...
2      web server perangkat lunak server berfungsi me...
```

```
3      penjadwalan kuliah perguruan kompleks permasal...
4      perkembangan teknologi didunia muncul teknolog...
                            ...
826    investasi saham memiliki resiko kerugian perge...
827    information retrieval ir pengambilan informasi...
828    klasifikasi citra proses pengelompokan piksel ...
829    identifikasi atribut pejalan kaki salah peneli...
830    topik deteksi objek menarik perhatian perkemba...
Name: abstrak, Length: 824, dtype: object
```

0.4 Steeming

Stemming merupakan proses untuk mengurangi kata-kata ke bentuk dasarnya atau akar kata. Tujuannya adalah untuk mengidentifikasi kata-kata yang memiliki akar yang sama, meskipun mereka mungkin memiliki akhiran atau imbuhan yang berbeda

```
factory = StemmerFactory()
stemmer = factory.create_stemmer()
```

```
steeming_abstrak = stopword_abstrak.apply(lambda text:stemmer.stem(text))
```

```
steeming_abstrak
```

```
0      sistem informasi akademik siakad sistem inform...
1      jalan koneksi jaring komputer lancar ganggu ha...
2      web server perangkat lunak server fungsi terim...
3      jadwal kuliah guru kompleks masalah variabel t...
4      kembang teknologi dunia muncul teknologi augme...
                            ...
826    investasi saham milik resiko rugi gera harga s...
827    information retrieval ir ambil informasi simpa...
828    klasifikasi citra proses kelompok piksel citra...
829    identifikasi atribut pejal kaki salah teliti k...
830    topik deteksi objek tarik perhati kembang tekn...
Name: abstrak, Length: 824, dtype: object
```

```
df['stopword-abstrak'] = stopword_abstrak
df['steeming-abstrak'] = steeming_abstrak
df.to_csv('/content/drive/My Drive/Task/Pencarian dan Penambangan Web/Tugas 1/data/processing-d
```

0

Feature Extraction

Feature extraction ini digunakan untuk mengubah keseluruhan teks dalam dokumen menjadi angka numerik dengan menggunakan algoritma TF-IDF dan LDA Topic

```
csv_preprocessing = '/content/drive/My Drive/Task/Pencarian dan Penambangan Web/Tugas 1/data/pr
data = pd.read_csv(csv_preprocessing)
data.head()
```

	penulis	judul	per
0	A.Ubaidillah S.Kom	PERANCANGAN DAN IMPLEMENTASI SISTEM DATABASE T...	Bu
1	M. Basith Ardianto,	APLIKASI KONTROL DAN MONITORING JARINGAN KOMPU...	Dr
2	Akhmad Suyandi, S.Kom	RANCANG BANGUN APLIKASI PROXY SERVER UNTUK\nEN...	Dr
3	Heri Supriyanto	SISTEM PENDUKUNG KEPUTUSAN OPTIMASI PENJADWALA...	Mu
4	Septian Rahman Hakim	SISTEM AUGMENTED REALITY ANIMASI BENDA BERGERA...	Ar

```
preprocessing = data.dropna(subset=['steeming-abstrak'])
```

```
preprocessing
```

	penulis	judul
0	A.Ubaidillah S.Kom	PERANCANGAN DAN IMPLEMENTASI SISTEM DATABASE T...
1	M. Basith Ardianto,	APLIKASI KONTROL DAN MONITORING JARINGAN KOMPU...
2	Akhmad Suyandi, S.Kom	RANCANG BANGUN APLIKASI PROXY SERVER UNTUK\nEN...
3	Heri Supriyanto	SISTEM PENDUKUNG KEPUTUSAN OPTIMASI PENJADWALA...
4	Septian Rahman Hakim	SISTEM AUGMENTED REALITY ANIMASI BENDA BERGERA...
...	...	...
819	Rachmad Agung Pambudi	PENERAPAN ALGORITMA LONG-SHORT TERM MEMORY UNT...
820	Nadila Hidayanti	SISTEM PENCARIAN TEKS AL-QURAN TERJEMAHAN BERB...
821	Afni Sakinah	KLASIFIKASI KOMPLEKSITAS VISUAL CITRA SAMPAH M...
822	Friska Fatmawatiningrum	IDENTIFIKASI BINER ATRIBUT PEJALAN KAKI MENGGU...
823	Dian Wibowo	DETEKSI OBJEK MANUSIA BERBASIS ONE STAGE DETEC...

```
get_steeming_abstrak = preprocessing["steeming-abstrak"]
get_stopword_abstrak = preprocessing["stopword-abstrak"]
```

0.5 Local Weighting

```
countvectorizer = CountVectorizer(analyzer= 'word')
term_matrix = countvectorizer.fit_transform(get_steeming_abstrak)
count_tokens = countvectorizer.get_feature_names_out()
df_countvect = pd.DataFrame(data = term_matrix.toarray(),columns = count_tokens)
print('Term Frequency\n')
df_countvect

# Transpose DataFrame
# df_countvect_transposed = df_countvect.T

# Print transposed DataFrame
# print('Term Frequency Transposed\n')
# df_countvect_transposed
```

```
Term Frequency
```

	aalysis	aam	ab	abad	abadi	abai	abdi	ability	abjad	absah	...	zara	zat	zcz	zf	zona
0	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
1	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
2	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
3	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
4	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
818	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
819	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
820	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
821	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
822	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0

```
countvectorizer = CountVectorizer(analyzer='word')

log_matrix = countvectorizer.fit_transform(get_steeming_abstrak)
```

```
count_tokens = countvectorizer.get_feature_names_out()

count_log_matrix = np.log1p(log_matrix)

df_log_countvect = pd.DataFrame(data=count_log_matrix.toarray(), columns=count_tokens)

print('Log Frequency\n')
df_log_countvect
```

```
Log Frequency
```

	aalysis	aam	ab	abad	abadi	abai	abdi	ability	abjad	absah	...	zara	zat	zcz	zf	zo
0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
1	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
2	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
4	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
818	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
819	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
820	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
821	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
822	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0

```
countvectorizer = CountVectorizer(analyzer='word', binary=True)

binary_matrix = countvectorizer.fit_transform(get_steeming_abstrak)
df_binary = pd.DataFrame(binary_matrix.toarray(), columns=countvectorizer.get_feature_names_out

print('Binary\n')
df_binary
```

```
Binary
```

	aalysis	aam	ab	abad	abadi	abai	abdi	ability	abjad	absah	...	zara	zat	zcz	zf	zona
0	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
1	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
2	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
3	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
4	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
818	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0

	aalysis	aam	ab	abad	abadi	abai	abdi	ability	abjad	absah	...	zara	zat	zcz	zf	zona
819	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
820	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
821	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0
822	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0

0.6 TF-IDF

TF-IDF adalah teknik yang digunakan untuk mengukur pentingnya kata-kata dalam suatu dokumen dalam konteks korpus dokumen yang lebih besar. Ini dapat digunakan untuk mengidentifikasi kata-kata kunci atau fitur penting dalam analisis teks dan Natural Language Processing

```
tfidfvectorizer = TfidfVectorizer(analyzer='word')
tfidf = tfidfvectorizer.fit_transform(get_steeming_abstrak)
tfidf_token = tfidfvectorizer.get_feature_names_out()
```

```
tfidf_df = pd.DataFrame(data = tfidf.toarray(), columns = tfidf_token)
tfidf_df
```

	aalysis	aam	ab	abad	abadi	abai	abdi	ability	abjad	absah	...	zara	zat	zcz	zf	zo
0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
1	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
2	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
4	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
818	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
819	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
820	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
821	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
822	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0

0.7 LDA Topic

```
document = [text.split() for text in get_stopword_abstrak]
document = [tokens for tokens in document if tokens]
dictionary = corpora.Dictionary(document)
corpus = [dictionary.doc2bow(tokens) for tokens in document]

num_topics = 3
lda_model = gensim.models.ldamodel.LdaModel(corpus=corpus,
                                            id2word=dictionary,
                                            num_topics=num_topics,
                                            random_state=100,
                                            passes=10,
                                            per_word_topics=True)


print(lda_model.print_topics())
doc_lda = lda_model[corpus]
```

```
[(0, '0.014*"game" + 0.013*"metode" + 0.012*"hasil" + 0.010*"sistem" + 0.010*"penelitian" + 0.008*"pen
```

```
topic_proportions_list = []

for index, doc in enumerate(corpus):
      topic_prop = lda_model.get_document_topics(doc)
      proportions = {f'Topic {i+1}': 0.0 for i in range(num_topics)}

      for topic in topic_prop:
          proportions[f'Topic {topic[0] + 1}'] = topic[1]
      topic_proportions_list.append(proportions)

topic_proportions = pd.DataFrame(topic_proportions_list)
topic_proportions_df = pd.DataFrame(topic_proportions_list)
topic_proportions_df.insert(0, 'judul', df['judul'])
topic_proportions_df.insert(4, 'label-topic', df['label-topic'])
topic_proportions_df
```

	judul	Topic 1	Topic 2	Topic
0	PERANCANGAN DAN IMPLEMENTASI SISTEM DATABASE T...	0.000000	0.000000	0.9904
1	APLIKASI KONTROL DAN MONITORING JARINGAN KOMPU...	0.000000	0.000000	0.9929
2	RANCANG BANGUN APLIKASI PROXY SERVER UNTUK\nEN...	0.993474	0.000000	0.0000

	judul	Topic 1	Topic 2	Topic
3	SISTEM PENDUKUNG KEPUTUSAN OPTIMASI PENJADWALA...	0.000000	0.000000	0.9888
4	SISTEM AUGMENTED REALITY ANIMASI BENDA BERGERA...	0.656224	0.000000	0.3390
...	...	...	...	...
818	Sistem Pendukung Keputusan Kelayakan Pemberian...	0.993347	0.000000	0.0000
819	Penerapan Metode Rubrik Analitik pada Sistem E...	0.990578	0.000000	0.0000
820	TEMU KEMBALI CITRA BERBASIS ISI BERBASIS FEATU...	0.376622	0.620967	0.0000
821	SISTEM PENDUKUNG KEPUTUSAN DIAGNOSIS PENYAKIT ...	0.000000	0.994340	0.0000
822	Implementasi Metode Double Moving Average untu...	0.000000	0.991276	0.0000

0

Clustering

Untuk melakukan clustering akan menggunakan hasil fitur yang didapatkan pada ekstraksi kalimat di tahapan sebelumnya dengan menggunakan TF-IDF dan LDA Topic. Kedua algoritma tersebut memiliki cara kerja yang berbeda maka dengan melakukukan perbandingan nilai skor yang dihasilkan pada saat clustering dokumen maka nanti dapat diambil kesimpulan dari hasil ektraksi fitur yang terbaik ketika menggunakan kedua algoritma tersebut.

```
def kmeans_clustering(data):
    scaler = StandardScaler()
    scaled_data = scaler.fit_transform(data)
    num_clusters = 3
    kmeans = KMeans(n_clusters=num_clusters, random_state=42)
    clusters = kmeans.fit_predict(scaled_data)
    return clusters
```

0.8 Clustering TF-IDF

```
tfidf_clusters = kmeans_clustering(tfidf_df.values)
silhouette_tfidf = silhouette_score(tfidf_df.values, tfidf_clusters)

tfidf_clusters_df = pd.DataFrame({'cluster':tfidf_clusters})
tfidf_clusters_df.insert(0, 'judul', data['judul'])
tfidf_clusters_df.insert(2, 'label-topic', data['label-topic'])

tfidf_clusters_df
```

```
/usr/local/lib/python3.10/dist-packages/sklearn/cluster/_kmeans.py:870: FutureWarning: The default v
  warnings.warn(
```

	judul	cluster	label-topic
0	PERANCANGAN DAN IMPLEMENTASI SISTEM DATABASE T...	0	rpl
1	APLIKASI KONTROL DAN MONITORING JARINGAN KOMPU...	0	rpl
2	RANCANG BANGUN APLIKASI PROXY SERVER UNTUK\nEN...	0	rpl
3	SISTEM PENDUKUNG KEPUTUSAN OPTIMASI PENJADWALA...	0	komputasi
4	SISTEM AUGMENTED REALITY ANIMASI BENDA BERGERA...	0	komputasi
...	...	...	...
818	MULTI CRITERIA DECISION MAKING UNTUK MENENTUKA...	0	komputasi
819	PENERAPAN ALGORITMA LONG-SHORT TERM MEMORY UNT...	0	komputasi
820	SISTEM PENCARIAN TEKS AL-QURAN TERJEMAHAN BERB...	0	komputasi
821	KLASIFIKASI KOMPLEKSITAS VISUAL CITRA SAMPAH M...	0	komputasi
822	IDENTIFIKASI BINER ATRIBUT PEJALAN KAKI MENGGU...	0	komputasi

```
  print('Silhouette TF-IDF', silhouette_tfidf)
```

```
Silhouette TF-IDF -0.010246924294755827
```

0.9 Clustering LDA Topic

```
  topic_proportions_clusters = kmeans_clustering(topic_proportions.values)
  silhouette_topic_proportions = silhouette_score(topic_proportions.values, topic_proportions_clu

  topic_proportions_df = pd.DataFrame({'cluster':topic_proportions_clusters})
  topic_proportions_df.insert(0, 'judul', data['judul'])
  topic_proportions_df.insert(2, 'label-topic', data['label-topic'])

  topic_proportions_df
```

```
/usr/local/lib/python3.10/dist-packages/sklearn/cluster/_kmeans.py:870: FutureWarning: The default v
  warnings.warn(
```

	judul	cluster	label-topic
0	PERANCANGAN DAN IMPLEMENTASI SISTEM DATABASE T...	0	rpl
1	APLIKASI KONTROL DAN MONITORING JARINGAN KOMPU...	0	rpl
2	RANCANG BANGUN APLIKASI PROXY SERVER UNTUK\nEN...	2	rpl
3	SISTEM PENDUKUNG KEPUTUSAN OPTIMASI PENJADWALA...	0	komputasi
4	SISTEM AUGMENTED REALITY ANIMASI BENDA BERGERA...	2	komputasi
...	...	...	...
818	MULTI CRITERIA DECISION MAKING UNTUK MENENTUKA...	2	komputasi

	judul	cluster	label-topic
819	PENERAPAN ALGORITMA LONG-SHORT TERM MEMORY UNT...	2	komputasi
820	SISTEM PENCARIAN TEKS AL-QURAN TERJEMAHAN BERB...	1	komputasi
821	KLASIFIKASI KOMPLEKSITAS VISUAL CITRA SAMPAH M...	1	komputasi
822	IDENTIFIKASI BINER ATRIBUT PEJALAN KAKI MENGGU...	1	komputasi

```
print('Silhouette LDA', silhouette_topic_proportions)
```

```
Silhouette LDA 0.7618316411660097
```

0

Classification

Sama halnya pada clustering, proses klasifikasi kali ini akan membandingkan antara kedua algoritma ektraksi fitur yaitu TF-IDF dan LDA Topic sehingga nanti akan dihasilkan perbandingan antara akurasi terbaik ketika menggunakan LDA atau TF-IDF

0.10 TF-IDF

0.10.1 KNN

```
X = tfidf_df
y = preprocessing['label-topic']
y = y.replace({'komputasi': 1, 'rpl': 0})

def train_knn_classifier(k):

    # train model knn
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

    knn_classifier = KNeighborsClassifier(n_neighbors=k)
    knn_classifier.fit(X_train, y_train)

    y_pred = knn_classifier.predict(X_test)


    # confusion matrix
    cm = confusion_matrix(y_test, y_pred)
    disp = ConfusionMatrixDisplay(confusion_matrix=cm)

    plt.figure(figsize=(4, 3))
    sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
    plt.xlabel('Predicted')
    plt.ylabel('Actual')
```

```
    plt.title(f'Confusion Matrix for k = {k}')
    plt.show()

    accuracy = accuracy_score(y_test, y_pred)
    precision = precision_score(y_test, y_pred)
    recall = recall_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred)

    print(
      '\nHasil Evaluasi Nilai K adalah',k,
      '\nAccuracy =', accuracy,
      '\nPrecision =', precision,
      '\nRecall =', recall,
      '\nF1 Score =', f1
    )
```

```
train_knn_classifier(5)
```

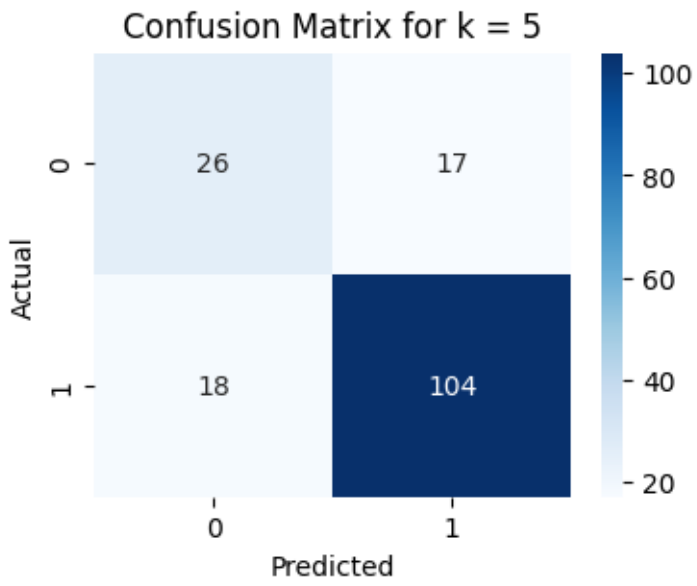


```
Hasil Evaluasi Nilai K adalah 5
Accuracy = 0.7878787878787878
Precision = 0.859504132231405
Recall = 0.8524590163934426
```

```
F1 Score = 0.8559670781893004
```

```
train_knn_classifier(7)
```

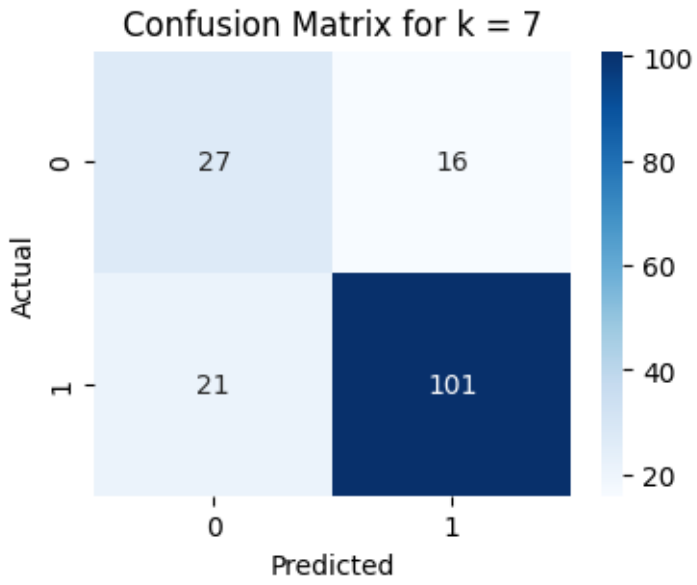


```
Hasil Evaluasi Nilai K adalah 7
Accuracy = 0.7757575757575758
Precision = 0.8632478632478633
Recall = 0.8278688524590164
F1 Score = 0.8451882845188285
```

```
train_knn_classifier(9)
```

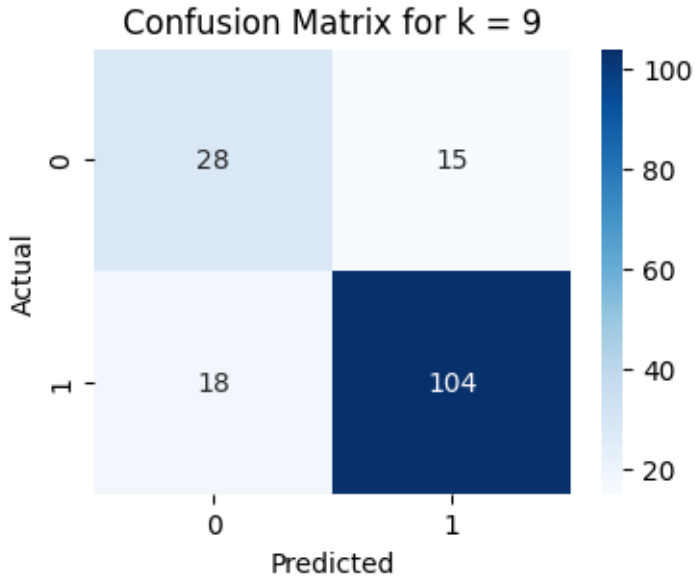


```
Hasil Evaluasi Nilai K adalah 9
Accuracy = 0.8
Precision = 0.8739495798319328
Recall = 0.8524590163934426
F1 Score = 0.8630705394190871
```

0.10.2 Naive Bayes

```
def train_naive_bayes_classifier():

    # train model naive bayes
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

    naive_bayes_classifier = MultinomialNB()
    naive_bayes_classifier.fit(X_train, y_train)

    y_pred = naive_bayes_classifier.predict(X_test)

    # confusion matrix
    cm = confusion_matrix(y_test, y_pred)
    disp = ConfusionMatrixDisplay(confusion_matrix=cm)
```

```
    plt.figure(figsize=(4, 3))
    sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
    plt.xlabel('Predicted')
    plt.ylabel('Actual')
    plt.title('Confusion Matrix for Naive Bayes Classifier')
    plt.show()

    accuracy = accuracy_score(y_test, y_pred)
    precision = precision_score(y_test, y_pred)
    recall = recall_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred)

    print(
      '\nHasil Evaluasi Naive Bayes Classifier:',
      '\nAccuracy =', accuracy,
      '\nPrecision =', precision,
      '\nRecall =', recall,
      '\nF1 Score =', f1
    )
```

```
train_naive_bayes_classifier()
```

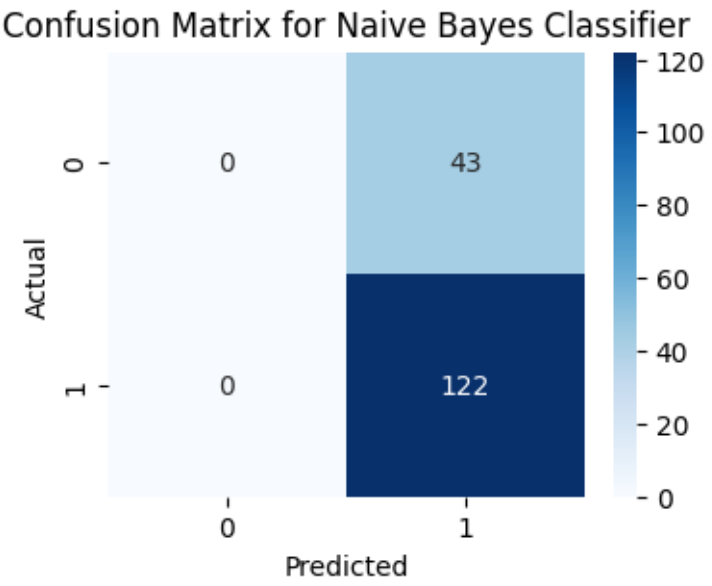

```
Hasil Evaluasi Naive Bayes Classifier:
Accuracy = 0.7393939393939394
Precision = 0.7393939393939394
Recall = 1.0
F1 Score = 0.8501742160278746
```

0.11 LDA Topic

0.11.1 KNN

```
X = topic_proportions
y = preprocessing['label-topic']
y = y.replace({'komputasi': 1, 'rpl': 0})

def train_knn_lda_classifier(k):

    # train model knn
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

    knn_classifier = KNeighborsClassifier(n_neighbors=k)
    knn_classifier.fit(X_train, y_train)

    y_pred = knn_classifier.predict(X_test)


    # confusion matrix
    cm = confusion_matrix(y_test, y_pred)
    disp = ConfusionMatrixDisplay(confusion_matrix=cm)

    plt.figure(figsize=(4, 3))
    sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
    plt.xlabel('Predicted')
    plt.ylabel('Actual')
    plt.title(f'Confusion Matrix for k = {k}')
    plt.show()

    accuracy = accuracy_score(y_test, y_pred)
    precision = precision_score(y_test, y_pred)
    recall = recall_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred)
```

```
    print(
      '\nHasil Evaluasi Nilai K adalah',k,
      '\nAccuracy =', accuracy,
      '\nPrecision =', precision,
      '\nRecall =', recall,
      '\nF1 Score =', f1
    )
```

```
train_knn_lda_classifier(3)
```

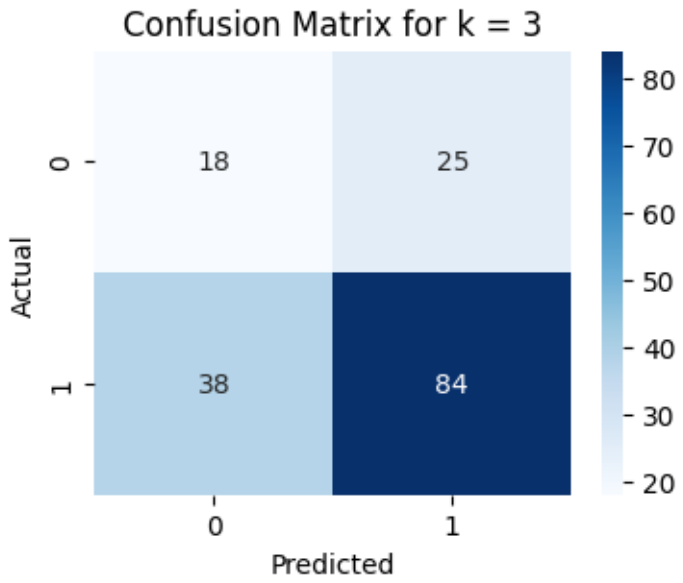


```
Hasil Evaluasi Nilai K adalah 3
Accuracy = 0.6181818181818182
Precision = 0.7706422018348624
Recall = 0.6885245901639344
F1 Score = 0.7272727272727273
```

```
train_knn_lda_classifier(5)
```

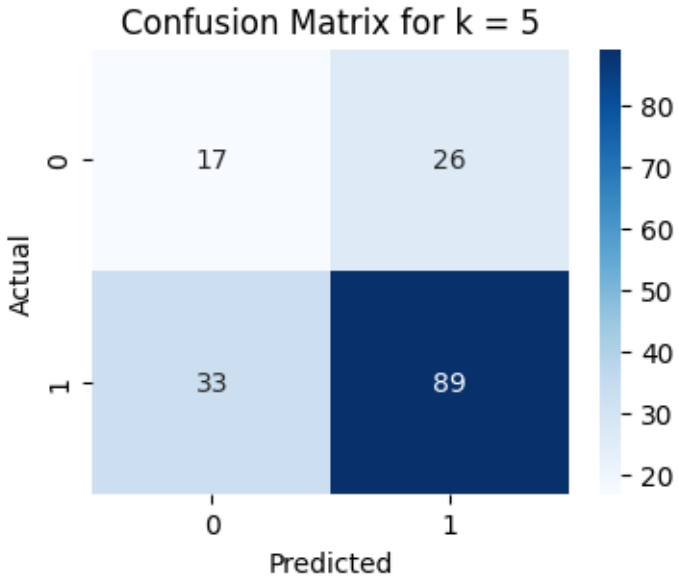


```
Hasil Evaluasi Nilai K adalah 5
Accuracy = 0.6424242424242425
Precision = 0.7739130434782608
Recall = 0.7295081967213115
F1 Score = 0.751054852320675
```

```
train_knn_lda_classifier(7)
```

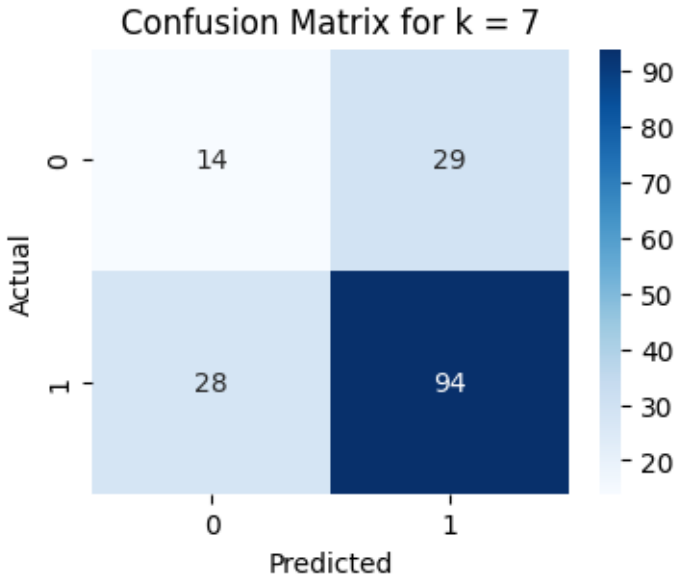


```
Hasil Evaluasi Nilai K adalah 7
Accuracy = 0.6545454545454545
Precision = 0.7642276422764228
Recall = 0.7704918032786885
F1 Score = 0.7673469387755102
```

```
  train_knn_lda_classifier(9)
```

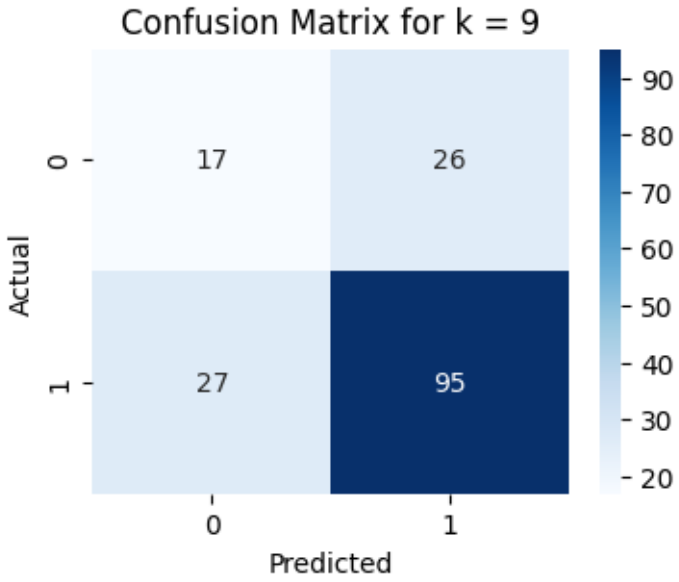


```
Hasil Evaluasi Nilai K adalah 9
Accuracy = 0.6787878787878788
Precision = 0.7851239669421488
Recall = 0.7786885245901639
F1 Score = 0.7818930041152264
```

0.11.2 Naive Bayes

```
def train_naive_bayes_classifier_lda():

    # train model naive bayes
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

    naive_bayes_classifier = MultinomialNB()
    naive_bayes_classifier.fit(X_train, y_train)

    y_pred = naive_bayes_classifier.predict(X_test)

    # confusion matrix
    cm = confusion_matrix(y_test, y_pred)
    disp = ConfusionMatrixDisplay(confusion_matrix=cm)
```

```
    plt.figure(figsize=(4, 3))
    sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
    plt.xlabel('Predicted')
    plt.ylabel('Actual')
    plt.title('Confusion Matrix for Naive Bayes Classifier')
    plt.show()

    accuracy = accuracy_score(y_test, y_pred)
    precision = precision_score(y_test, y_pred)
    recall = recall_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred)

    print(
      '\nHasil Evaluasi Naive Bayes Classifier:',
      '\nAccuracy =', accuracy,
      '\nPrecision =', precision,
      '\nRecall =', recall,
      '\nF1 Score =', f1
    )
```

```
train_naive_bayes_classifier_lda()
```

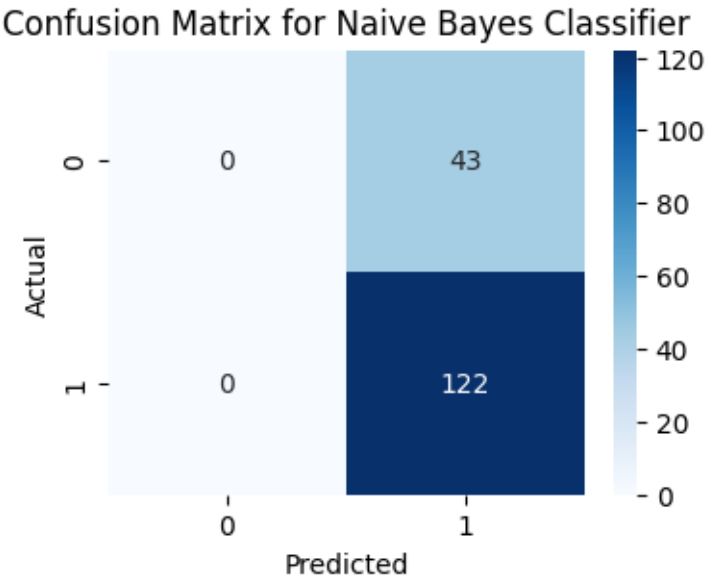

```
Hasil Evaluasi Naive Bayes Classifier:
Accuracy = 0.7393939393939394
Precision = 0.7393939393939394
Recall = 1.0
F1 Score = 0.8501742160278746
```

0

Save Model

```
joblib.dump(tfidfvectorizer, 'tfidf_vectorizer')
```

```
['tfidf_vectorizer']
```

```
X = tfidf_df
y = preprocessing['label-topic']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

```
knn_classifier = KNeighborsClassifier(n_neighbors=9)
knn_classifier.fit(X_train, y_train)
y_pred = knn_classifier.predict(X_test)
```

```
joblib.dump(knn_classifier, 'knn_model')
```

```
['knn_model']
```

0

Crawl Berita CNN

```
!pip install requests
!pip install beautifulsoup4
!pip install tqdm
```

```
Requirement already satisfied: requests in /usr/local/lib/python3.10/dist-packages (2.31.0)
Requirement already satisfied: charset-normalizer<4,>=2 in /usr/local/lib/python3.10/dist-packages (
Requirement already satisfied: idna<4,>=2.5 in /usr/local/lib/python3.10/dist-packages (from requests
Requirement already satisfied: urllib3<3,>=1.21.1 in /usr/local/lib/python3.10/dist-packages (from re
Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.10/dist-packages (from re
Requirement already satisfied: beautifulsoup4 in /usr/local/lib/python3.10/dist-packages (4.11.2)
Requirement already satisfied: soupsieve>1.2 in /usr/local/lib/python3.10/dist-packages (from beautif
Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-packages (4.66.1)
```

```
import requests
from bs4 import BeautifulSoup
import pandas as pd
from tqdm.auto import tqdm
```

0

Crawling Data

Teknik crawling data adalah proses pengumpulan informasi dari berbagai sumber di internet secara otomatis. Crawling data dilakukan oleh program yang disebut "web crawler". Web crawler pada proses ini menggunakan beautifulsoup untuk melakukan ekstraksi halaman konten tersebut agar dapat mengambil isi-isi konten pada berita di website CNN Indonesia. Terdapat juga libraly request yang digunakan untuk meminta respon pada situs yang akan dilakukan crawling data.

```
from os import replace
def cnnnews(page):

    data = {'judul': [], 'berita': []}
    for i in tqdm(range(1, page+1)):
      url = f"https://www.cnnindonesia.com/nasional/indeks/3/{i}"
      r = requests.get(url)
      request = r.content
      soup = BeautifulSoup(request, 'html.parser')
      soup = soup.find('div', {'class': 'flex flex-col gap-5'})
      news = soup.findAll('article', {'class': 'flex-grow'})
      # news = soup.findAll('a', {'aria-label': 'link description'})

      for new in tqdm(news):
        a_element = new.find('a', {'aria-label': 'link description'})['href']
        detail_request = requests.get(a_element)
        detail_soup = BeautifulSoup(detail_request.content, 'html.parser')

        judul = detail_soup.find('h1', {'class': 'leading-9'})
        berita = detail_soup.find('div', {'class': 'detail-text'})

        if judul and berita:
          judul = judul.text
          berita = berita.text
          noise = detail_soup.find('strong').text

          berita = berita.replace("ADVERTISEMENT", "").replace("SCROLL TO CONTINUE WITH CONTENT
```

```
            berita = ' '.join(berita.split())
            data["judul"].append(judul)
            data["berita"].append(berita)

    df = pd.DataFrame(data)
    df.to_csv("berita-cnn.csv", index=False)

    return df
```

```
cnnnews(5)
```

```
0%|          | 0/5 [00:00<?, ?it/s]
0%|          | 0/10 [00:00<?, ?it/s]
0%|          | 0/10 [00:00<?, ?it/s]
0%|          | 0/10 [00:00<?, ?it/s]
0%|          | 0/10 [00:00<?, ?it/s]
0%|          | 0/10 [00:00<?, ?it/s]
```

	judul	berita
0	Dirjen Kemendagri Safrizal ZA Jadi Pj Gubernu...	Menteri Dalam Negeri (Mendagri) Tito Karna
1	Ganjar Temui Gus Mus di Rembang, Bahas Polemi...	Bakal capres PDIP Ganjar Pranowo mengunj
2	Nomor Urut Capres-Cawapres Diundi KPU Besok	Komisi Pemilihan Umum (KPU) RI bakal me
3	Utut Adianto Pimpin Panja Netralitas TNI di P...	Komisi I DPR sudah menyepakati pembentuk
4	Istri Cak Nur Curhat ke Gus Mus: Nepotisme Di...	Sejumlah tokoh bangsa yang mengatasnamak
5	Eks Stafsus SBY Velix Wanggai Jadi Pj Gubernu...	Presiden Joko Widodo menunjuk mantan Sta
6	KPU Resmi Tetapkan Prabowo, Ganjar, Anies seb...	Komisi Pemilihan Umum (KPU) resmi menet
7	Eks Kadis PUPR Papua Didakwa Terima Suap & Gr...	Kepala Dinas Pekerjaan Umum dan Perumah
8	Fatia Maulidiyanti Dituntut 3,5 Tahun Penjara...	Aktivitis Hak Asasi Manusia (HAM) Fatia M
9	KPK Panggil Keponakan SYL Istri Kapolrestabes...	Komisi Pemberantasan Korupsi (KPK) mema
10	Haris Azhar Dituntut 4 Tahun Penjara Kasus Lo...	Aktivitis Hak Asasi Manusia (HAM) Haris A
11	KPK Dalami Dugaan Kartu Anggota Kasino SYL	Komisi Pemberantasan Korupsi (KPK) tenga
12	Pelecehan Anggota BEM UNY Hoaks, Polisi Tangk...	Polisi memastikan dugaan kasus pelecehan m
13	Dinkes DKI: Kasus Cacar Monyet di Jakarta Cap...	Dinas Kesehatan (Dinkes) DKI Jakarta melap
14	Pemkab Ungkap Susun 6 Dimensi pada Perencanaa...	Kabupaten Klaten menyatakan memiliki enar
15	Sri Mulyani Sebut Petugas Kesehatan Merupakan...	Pemerintah Kabupaten Klaten menggelar Up
16	Klaten Ambil Bagian pada Evaluasi Tahap II Sm...	Kabupaten Klaten turut ambil bagian sebaga
17	Puncak Peringatan HKN Ke-59, Bupati Klaten Ap...	Bupati Klaten, Jawa Tengah, Sri Mulyani, m
18	Nakes Klaten Diminta Jadi Pelopor Budaya Hidu...	Bupati Klaten, Sri Mulyani, meminta tenaga
19	FOTO: Suhartoyo Resmi Jadi Ketua MK Gantikan ...	Hakim konstitusi Suhartoyo resmi dilantik se
20	Fit and Proper Test Panglima TNI Singgung Isu...	Calon Panglima TNI Jenderal Agus Subiyant
21	Kapolda Metro Sebut Tersangka Kasus Pemerasan...	Kapolda Metro Jaya Irjen Karyoto menyebut

	judul	berita
22	Irjen Karyoto soal Firli: Kita Lihat Saja Bes...	Kapolda Metro Jaya Irjen Karyoto angkat su
23	Suhartoyo Janji Segera Bentuk MKMK Permanen	Ketua Mahkamah Konstitusi (MK) Suhartoy
24	Mahfud Singgung Menteri Jokowi Ditangkap Koru...	Menko Polhukam Mahfud MD menyinggung
25	Mahfud Respons Dugaan Saling Sandera KPK-Pold...	Menko Polhukam Mahfud MD angkat suara s
26	Agus Subiyanto di DPR: Jika Ingin Damai, Bers...	Kepala Staf Angkatan Darat (KSAD) sekalig
27	OTT KPK di Sorong Terkait Pengondisian Temuan...	Komisi Pemberantasan Korupsi (KPK) meng
28	KPK Total Tangkap 5 Orang Terkait OTT di Sorong	Komisi Pemberantasan Korupsi (KPK) total
29	Anwar Usman Absen di Pelantikan Ketua MK, Izi...	Hakim Konstitusi Anwar Usman tidak hadir
30	KPK Total Tangkap 5 Orang Terkait OTT di Sorong	Komisi Pemberantasan Korupsi (KPK) total
31	Anwar Usman Absen di Pelantikan Ketua MK, Izi...	Hakim Konstitusi Anwar Usman tidak hadir
32	Komisi I DPR Sepakati Agus Subiyanto Jadi Pan...	Komisi I DPR secara resmi menyepakati KSA
33	Jelang Penetapan Capres-Cawapres, Jalan Depan...	Jalan Imam Bonjol depan kantor Komisi Pem
34	Massa Atribut Serba Hitam Demo di KPU Jelang ...	Demonstrasi terjadi di depan kantor Komisi I
35	PAN Solid Dukung Prabowo-Gibran dan Menang Pi...	Wakil Bendahara Umum Partai Amanat Nasi
36	LHKPN Ketua MK Suhartoyo, Punya Harta Rp14,7 ...	Ketua Mahkamah Konstitusi (MK) terpilih p
37	Fit & Proper Test, Agus Janji Ingatkan Prajur...	Calon Panglima TNI Jenderal Agus Subiyant
38	Yasonna soal Wamenkumham Jadi Tersangka: Sila...	Menteri Hukum dan Hak Asasi Manusia (Me
39	Ketua MK Suhartoyo Menangis Saat Pidato Soal ...	Hakim Mahkamah Konstitusi (MK) Suhartoy
40	Bahlil Heran Gibran Dipersoalkan: Banyak Ment...	Ketua Dewan Pembina Relawan Pengusaha M
41	Gibran: Laporkan Saja ke Bawaslu Jika Ada Kec...	Wali Kota Solo sekaligus bakal cawapres Gibr
42	Bupati Dhito: Batik Kediri Siap Masuk Kancah ...	Bupati Kediri Hanindhito Himawan Pramana
43	Sempat Macet Parah, Jalan Mampang Prapatan Ar...	Kemacetan sempat terjadi di Jalan Mampang
44	Pejabat Sorong dan Pegawai BPK Terjaring OTT ...	Komisi Pemberantasan Korupsi (KPK) melak
45	Fit and Proper Test Calon Panglima TNI, Jende...	Kepala Staf Angkatan Darat (KSAD) sekalig
46	VIDEO: Momen Suhartoyo Resmi Dilantik Jadi Ke...	Mahkamah Konstitusi resmi melantik Suharto
47	Wali Kota Semarang Ingin Masyarakat Tak Berga...	Festival pangan pendamping beras bertajuk F
48	Panglima TNI-Kapolri ke Rumah Agus Subiyanto ...	Panglima TNI Laksamana Yudo Margono dan
49	Suhartoyo Resmi Jadi Ketua MK Gantikan Anwar ...	Hakim konstitusi Suhartoyo resmi dilantik sel

0

Ringkasan Berita

Aplikasi untuk ringkasan berita Berita Ringkas[2]

[2] https://https://syayidalaziz-berita-ringkas.hf.space/

0

Instalasi

```
!pip install rouge
```

```
Requirement already satisfied: rouge in /usr/local/lib/python3.10/dist-packages (1.0.1)
Requirement already satisfied: six in /usr/local/lib/python3.10/dist-packages (from rouge) (1.16.0)
```

```
import pandas as pd
import nltk
import networkx as nx
import matplotlib.pyplot as plt
import re
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics.pairwise import cosine_similarity
from nltk.corpus import stopwords
from rouge import Rouge
```

```
nltk.download('punkt')
nltk.download("stopwords")
```

```
[nltk_data] Downloading package punkt to /root/nltk_data...
[nltk_data]   Package punkt is already up-to-date!
[nltk_data] Downloading package stopwords to /root/nltk_data...
[nltk_data]   Package stopwords is already up-to-date!
```

```
True
```

0

Data

Data yang digunakan menggunakan hasil crawling data pada website CNN Indonesia dalam kategori berita nasional.

```
from google.colab import drive
drive.mount('/content/drive')

csv_path = '/content/drive/My Drive/Task/Pencarian dan Penambangan Web/Tugas 2/data/berita-cnn.
df = pd.read_csv(csv_path)
df
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/dr
```

	judul	berita
0	Dirjen Kemendagri Safrizal ZA Jadi Pj Gubernu...	Menteri Dalam Negeri (Mendagri) Tito Karna
1	Ganjar Temui Gus Mus di Rembang, Bahas Polemi...	Bakal capres PDIP Ganjar Pranowo mengunj
2	Nomor Urut Capres-Cawapres Diundi KPU Besok	Komisi Pemilihan Umum (KPU) RI bakal me
3	Utut Adianto Pimpin Panja Netralitas TNI di P...	Komisi I DPR sudah menyepakati pembentuk
4	Istri Cak Nur Curhat ke Gus Mus: Nepotisme Di...	Sejumlah tokoh bangsa yang mengatasnamak
5	Eks Stafsus SBY Velix Wanggai Jadi Pj Gubernu...	Presiden Joko Widodo menunjuk mantan Sta
6	KPU Resmi Tetapkan Prabowo, Ganjar, Anies seb...	Komisi Pemilihan Umum (KPU) resmi menet
7	Eks Kadis PUPR Papua Didakwa Terima Suap & Gr...	Kepala Dinas Pekerjaan Umum dan Perumah
8	Fatia Maulidiyanti Dituntut 3,5 Tahun Penjara...	Aktivitis Hak Asasi Manusia (HAM) Fatia M
9	KPK Panggil Keponakan SYL Istri Kapolrestabes...	Komisi Pemberantasan Korupsi (KPK) mema
10	Haris Azhar Dituntut 4 Tahun Penjara Kasus Lo...	Aktivitis Hak Asasi Manusia (HAM) Haris A
11	KPK Dalami Dugaan Kartu Anggota Kasino SYL	Komisi Pemberantasan Korupsi (KPK) tenga
12	Pelecehan Anggota BEM UNY Hoaks, Polisi Tangk...	Polisi memastikan dugaan kasus pelecehan m
13	Dinkes DKI: Kasus Cacar Monyet di Jakarta Cap...	Dinas Kesehatan (Dinkes) DKI Jakarta melap
14	Pemkab Ungkap Susun 6 Dimensi pada Perencanaa...	Kabupaten Klaten menyatakan memiliki enar
15	Sri Mulyani Sebut Petugas Kesehatan Merupakan...	Pemerintah Kabupaten Klaten menggelar Up
16	Klaten Ambil Bagian pada Evaluasi Tahap II Sm...	Kabupaten Klaten turut ambil bagian sebaga
17	Puncak Peringatan HKN Ke-59, Bupati Klaten Ap...	Bupati Klaten, Jawa Tengah, Sri Mulyani, me
18	Nakes Klaten Diminta Jadi Pelopor Budaya Hidu...	Bupati Klaten, Sri Mulyani, meminta tenaga
19	FOTO: Suhartoyo Resmi Jadi Ketua MK Gantikan ...	Hakim konstitusi Suhartoyo resmi dilantik sel
20	Fit and Proper Test Panglima TNI Singgung Isu...	Calon Panglima TNI Jenderal Agus Subiyant
21	Kapolda Metro Sebut Tersangka Kasus Pemerasan...	Kapolda Metro Jaya Irjen Karyoto menyebut

	judul	berita
22	Irjen Karyoto soal Firli: Kita Lihat Saja Bes...	Kapolda Metro Jaya Irjen Karyoto angkat su
23	Suhartoyo Janji Segera Bentuk MKMK Permanen	Ketua Mahkamah Konstitusi (MK) Suhartoy
24	Mahfud Singgung Menteri Jokowi Ditangkap Koru...	Menko Polhukam Mahfud MD menyinggung
25	Mahfud Respons Dugaan Saling Sandera KPK-Pold...	Menko Polhukam Mahfud MD angkat suara s
26	Agus Subiyanto di DPR: Jika Ingin Damai, Bers...	Kepala Staf Angkatan Darat (KSAD) sekalig
27	OTT KPK di Sorong Terkait Pengondisian Temuan...	Komisi Pemberantasan Korupsi (KPK) meng
28	KPK Total Tangkap 5 Orang Terkait OTT di Sorong	Komisi Pemberantasan Korupsi (KPK) total
29	Anwar Usman Absen di Pelantikan Ketua MK, Izi...	Hakim Konstitusi Anwar Usman tidak hadir
30	KPK Total Tangkap 5 Orang Terkait OTT di Sorong	Komisi Pemberantasan Korupsi (KPK) total
31	Anwar Usman Absen di Pelantikan Ketua MK, Izi...	Hakim Konstitusi Anwar Usman tidak hadir
32	Komisi I DPR Sepakati Agus Subiyanto Jadi Pan...	Komisi I DPR secara resmi menyepakati KSA
33	Jelang Penetapan Capres-Cawapres, Jalan Depan...	Jalan Imam Bonjol depan kantor Komisi Pem
34	Massa Atribut Serba Hitam Demo di KPU Jelang ...	Demonstrasi terjadi di depan kantor Komisi I
35	PAN Solid Dukung Prabowo-Gibran dan Menang Pi...	Wakil Bendahara Umum Partai Amanat Nasi
36	LHKPN Ketua MK Suhartoyo, Punya Harta Rp14,7 ...	Ketua Mahkamah Konstitusi (MK) terpilih p
37	Fit & Proper Test, Agus Janji Ingatkan Prajur...	Calon Panglima TNI Jenderal Agus Subiyant
38	Yasonna soal Wamenkumham Jadi Tersangka: Sila...	Menteri Hukum dan Hak Asasi Manusia (Me
39	Ketua MK Suhartoyo Menangis Saat Pidato Soal ...	Hakim Mahkamah Konstitusi (MK) Suhartoy
40	Bahlil Heran Gibran Dipersoalkan: Banyak Ment...	Ketua Dewan Pembina Relawan Pengusaha M
41	Gibran: Laporkan Saja ke Bawaslu Jika Ada Kec...	Wali Kota Solo sekaligus bakal cawapres Gibr
42	Bupati Dhito: Batik Kediri Siap Masuk Kancah ...	Bupati Kediri Hanindhito Himawan Pramana
43	Sempat Macet Parah, Jalan Mampang Prapatan Ar...	Kemacetan sempat terjadi di Jalan Mampang
44	Pejabat Sorong dan Pegawai BPK Terjaring OTT ...	Komisi Pemberantasan Korupsi (KPK) melak
45	Fit and Proper Test Calon Panglima TNI, Jende...	Kepala Staf Angkatan Darat (KSAD) sekalig
46	VIDEO: Momen Suhartoyo Resmi Dilantik Jadi Ke...	Mahkamah Konstitusi resmi melantik Suharto
47	Wali Kota Semarang Ingin Masyarakat Tak Berga...	Festival pangan pendamping beras bertajuk F
48	Panglima TNI-Kapolri ke Rumah Agus Subiyanto ...	Panglima TNI Laksamana Yudo Margono dan
49	Suhartoyo Resmi Jadi Ketua MK Gantikan Anwar ...	Hakim konstitusi Suhartoyo resmi dilantik sel

Untuk meringkas suatu dokumen, maka kita hanya memerlukan satu sampel berita yang akan digunakan dengan menggunakan berita pertama

```
berita = df['berita'].iloc[0]
```

0

Preprocessing

Pada analisis ringkasan dokumen kali ini akan menggunakan 2 metode pengujian, pengujian pertama akan dilakukan langkah ringkasan berita tanpa menggunakan preprocessing dan tahapan pengujian kedua berita yang diringkas akan menggunakan tahapan preprocessing. Tahapan preprocessing ini antara lain yaitu menghapus angka, simbol dan stopword pada berita.

```
def preprocessing(text):
    text = re.sub(r'\d+', '', text)
    text = re.sub(r'[^\w\s.]', '', text)
    text = text.lower()

    stop_words = set(stopwords.words('indonesian'))
    words = text.split()
    filtered_words = [word for word in words if word.lower() not in stop_words]

    preprocessing_text = ' '.join(filtered_words)

    return preprocessing_text
```

```
kalimat_preprocessing = preprocessing(berita)
```

0

Ekstraksi Fitur

Ekstraksi fitur pada tahapan ini menggunakan TF-IDF untuk membentuk vektor pada setiap kalimatnya, sedangkan fitur yang akan digunakan pada vektor TF-IDF ini meliputi *term* pada keseluruhan dokumen.

```
kalimat = nltk.sent_tokenize(berita) #memecah dokumen berdasarkan kalimatnya tanpa preprocessin
```

```
kalimat_preprocessing = nltk.sent_tokenize(kalimat_preprocessing) #memecah dokumen berdasarkan
```

0.12 TF-IDF

Term Frequency-Inverse Document Frequency (TF-IDF) adalah vektor yang digunakan untuk mengevaluasi pentingnya kata-kata dalam sebuah dokumen. Nilai frekuensi kemunculan kata dalam setiap dokumen ini menunjukkan seberapa penting kata tersebut dalam dokumen. Berikut merupakan rumus untuk menghitung TF-IDF:

$$W_{d,t} = tf_{t,d} \cdot idf_{t,d}$$

Keterangan = $W_{d,t}$ = Nilai T*erm Frequency* untuk *term* (t) dalam dokumen (d). $tf_{t,d}$ = Frekuensi kemunculan *term* (t) dalam dokumen (d). $idf_{t,d}$ = Inverse Document Frequency Nilai kebalikan frekuensi dokumen *term* (t) dalam dokumen (d). Pada dasarnya TF-IDF adalah gabungan dari *Term Frequency* (TF) dan *Inverse Document Frequency* (IDF) sehingga sebelum kita membentuk nilai TFIDF, maka kita harus menghitung kedua nilai tersebut. *Term Frequency* (TF) merupakan perhitungan yang digunakan untuk menentukan seberapa sering kata-kata muncul dalam sebuah dokumen.

$$tf = \frac{tf}{max(tf)}$$

Keterangan = tf = banyaknya kata yang dicari dalam dokumen max (tf) = jumlah kemunculan term terbanyak pada dokumen yang sama

Sedangkan *Inverse Document Frequency* (IDF) menilai kata-kata yang sering

muncul sebagai kurang signifikan karena kemunculannya dalam banyak dokumen. Semakin rendah nilai IDF, maka kata tersebut akan dianggap kurang berarti dan sebaliknya, semakin tinggi nilai IDF maka kata tersebut akan dianggap lebih relevan atau penting dalam dokumen tersebut.

$$idf_t = \frac{D}{max(df_t)}$$

Keterangan = D = total dokumen $df\ (t)$ = jumlah dokumen yang mengandung *term* (t)

TF-IDF Tanpa Preprocessing

```
tfidf_vectorizer = TfidfVectorizer()
tfidf = tfidf_vectorizer.fit_transform(kalimat)

terms = tfidf_vectorizer.get_feature_names_out()
tfidf = pd.DataFrame(data=tfidf.toarray(), columns=terms)

tfidf
```

	11	13	19	2024	adalah	administrasi	adwil	akan	awasi	b
0	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
1	0.269719	0.269719	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
2	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
3	0.000000	0.000000	0.000000	0.000000	0.162701	0.000000	0.000000	0.207738	0.000000	0
4	0.255375	0.255375	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
5	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
6	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
7	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
8	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
9	0.000000	0.000000	0.000000	0.312276	0.000000	0.000000	0.000000	0.000000	0.000000	0
10	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
11	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
12	0.000000	0.000000	0.000000	0.000000	0.194693	0.248586	0.248586	0.000000	0.248586	0
13	0.000000	0.000000	0.279549	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
14	0.000000	0.000000	0.000000	0.000000	0.279706	0.000000	0.000000	0.000000	0.000000	0
15	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0
16	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0

TF-IDF Menggunakan Preprocessing

```
tfidf_vectorizer = TfidfVectorizer()
tfidf_preprocessing = tfidf_vectorizer.fit_transform(kalimat_preprocessing)
```

```
terms = tfidf_vectorizer.get_feature_names_out()
tfidf_preprocessing = pd.DataFrame(data=tfidf_preprocessing.toarray(), columns=terms)

tfidf_preprocessing
```

	administrasi	adwil	awasi	bangka	bapakbapak	belitung	berharap	berjalan	berperan
0	0.000000	0.000000	0.000000	0.294052	0.0000	0.294052	0.000000	0.000000	0.000000
1	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000
2	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000
3	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.308065	0.000000	0.000000
4	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.380838	0.000000
5	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000
6	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000
7	0.000000	0.000000	0.000000	0.260917	0.0000	0.260917	0.000000	0.000000	0.000000
8	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000
9	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000
10	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000
11	0.000000	0.000000	0.000000	0.000000	0.2477	0.000000	0.216287	0.000000	0.000000
12	0.261989	0.261989	0.261989	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000
13	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.358922
14	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000
15	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000
16	0.000000	0.000000	0.000000	0.000000	0.0000	0.000000	0.000000	0.000000	0.000000

0

Membentuk Graph

Dalam meringkas dokumen ini diperlukan untuk membentuk graph sebagai gambaran antara kedekatan pada masing-masing kalimat, sehingga dalam ringkasan dokumen yang dihasilkan akan memunculkan kalimat-kalimat penting dan memiliki kedekatan di setiap dokumennya.

0.13 Cosine Similarity

Cosine similarity digunakan untuk mengukur seberapa mirip dua vektor dalam ruang berdimensi banyak. Hasil dari *cosine similarity* ini akan menentukan apakah vektor tersebut menuju ke arah yang sama. Semakin kecil sudut antara dua vektor, maka semakin mirip satu sama lain sedangkan begitu juga sebaliknya, semakin besar nilai *cosine similarity* maka vektor tersebut dianggap jauh kemiripannya. Dalam ringkasan dokumen ini penting untuk menghitung nilai *cosine similarity* untuk mengetahui hubungan kesamaan antara kalimat satu dengan kalimat lainnya. Vektor yang digunakan untuk menghitung nilai *cosine simmilarity* ini adalah hasil dari TF-IDF pada langkah sebelumnya. Berikut merupakan rumus yang digunakan untuk menghitung nilai *cosine simmilarity*.

$$simmilarity(A, B) = \frac{A \cdot B}{|A||B|}$$

Keterangan = A.B = Vector dot product dari A dan B dihitung dengan $\sum_{i=1}^{n} x_k y_k$ |A| = Panjang vektor A dihitung dengan $\sum_{i=1}^{n} x_k^2$ |B| = Panjang vektor A dihitung dengan $\sum_{i=1}^{n} y_k^2$

Cosine Similarity Tanpa Preprocessing

```
cosine = cosine_similarity(tfidf, tfidf)
```

```
similarity = pd.DataFrame(cosine, columns=range(len(kalimat)), index=range(len(kalimat)))
similarity
```

	0	1	2	3	4	5	6	7	8	9
0	1.000000	0.000000	0.183156	0.031750	0.077184	0.106877	0.000000	0.234579	0.000000	0.034
1	0.000000	1.000000	0.000000	0.000000	0.206638	0.000000	0.041888	0.035372	0.048745	0.000
2	0.183156	0.000000	1.000000	0.000000	0.034132	0.112296	0.060918	0.276659	0.200600	0.096
3	0.031750	0.000000	0.000000	1.000000	0.000000	0.000000	0.000000	0.000000	0.058014	0.000
4	0.077184	0.206638	0.034132	0.000000	1.000000	0.032889	0.000000	0.000000	0.000000	0.033
5	0.106877	0.000000	0.112296	0.000000	0.032889	1.000000	0.000000	0.187934	0.000000	0.083
6	0.000000	0.041888	0.060918	0.000000	0.000000	0.000000	1.000000	0.036043	0.049670	0.060
7	0.234579	0.035372	0.276659	0.000000	0.000000	0.187934	0.036043	1.000000	0.210924	0.000
8	0.000000	0.048745	0.200600	0.058014	0.000000	0.000000	0.049670	0.210924	1.000000	0.000
9	0.034685	0.000000	0.096883	0.000000	0.033780	0.083440	0.060291	0.000000	0.000000	1.000
10	0.116650	0.000000	0.032666	0.029594	0.041664	0.083680	0.000000	0.027517	0.000000	0.000
11	0.067043	0.000000	0.041731	0.075541	0.059209	0.101223	0.171626	0.017577	0.099860	0.091
12	0.077952	0.058545	0.033793	0.031677	0.000000	0.032563	0.000000	0.068995	0.000000	0.000
13	0.042725	0.000000	0.000000	0.044278	0.041611	0.000000	0.000000	0.000000	0.000000	0.000
14	0.000000	0.047528	0.057351	0.045509	0.000000	0.000000	0.048430	0.089207	0.222667	0.000
15	0.000000	0.000000	0.000000	0.000000	0.061096	0.042397	0.000000	0.055524	0.000000	0.043
16	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000

Cosine Similarity Menggunakan Preprocessing

```
cosine_preprocessing = cosine_similarity(tfidf_preprocessing, tfidf_preprocessing)
```

```
similarity_preprocessing = pd.DataFrame(cosine_preprocessing, columns=range(len(kalimat)), inde
similarity_preprocessing
```

	0	1	2	3	4	5	6	7	8	9
0	1.000000	0.000000	0.152651	0.060469	0.047436	0.131893	0.000000	0.295745	0.000000	0.043
1	0.000000	1.000000	0.000000	0.000000	0.105852	0.000000	0.000000	0.000000	0.000000	0.000
2	0.152651	0.000000	1.000000	0.000000	0.054547	0.151663	0.000000	0.381721	0.316919	0.050
3	0.060469	0.000000	0.000000	1.000000	0.000000	0.000000	0.000000	0.000000	0.126832	0.000
4	0.047436	0.105852	0.054547	0.000000	1.000000	0.047130	0.000000	0.000000	0.000000	0.049
5	0.131893	0.000000	0.151663	0.000000	0.047130	1.000000	0.000000	0.156279	0.000000	0.043
6	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	1.000000	0.000000	0.000000	0.000
7	0.295745	0.000000	0.381721	0.000000	0.000000	0.156279	0.000000	1.000000	0.244551	0.000
8	0.000000	0.000000	0.316919	0.126832	0.000000	0.000000	0.000000	0.244551	1.000000	0.000
9	0.043678	0.000000	0.050225	0.000000	0.049395	0.043396	0.000000	0.000000	0.000000	1.000
10	0.112841	0.000000	0.054610	0.068464	0.000000	0.047184	0.000000	0.042140	0.000000	0.000
11	0.104161	0.000000	0.070955	0.111109	0.034891	0.061307	0.097365	0.027376	0.000000	0.098
12	0.092131	0.072819	0.043710	0.000000	0.000000	0.037766	0.000000	0.081749	0.000000	0.000
13	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000
14	0.000000	0.000000	0.087843	0.000000	0.000000	0.000000	0.000000	0.067784	0.106957	0.000

	0	1	2	3	4	5	6	7	8	9
15	0.000000	0.000000	0.000000	0.000000	0.083649	0.000000	0.000000	0.000000	0.000000	0.000
16	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000

0.14 Graph

Hasil dari nilai *cosine simmilarity* ini akan dapat digunakan untuk membentuk graph dengan menggunakan modul nx.graph. Graph ini akan menggambarkan ilustrasi dari kedekatan setiap kalimatnya dalam berita tersebut. Dalam proses penggambaran graph tersebut diperlukan ambang batas (*treshold*) yang digunakan untuk memberikan batasan agar keseluruhan kalimatnya tidak dihubungkan menggunakan garis *(edge)*. Nilai ambang batas (*treshold*) yang digunakan adalah 0.1

Graph Tanpa Preprocessing

```
G = nx.DiGraph()
for i in range(len(cosine)):
    G.add_node(i)

for i in range(len(cosine)):
    for j in range(len(cosine)):
        similarity = cosine[i][j]
        if similarity > 0.1 and i != j:
            G.add_edge(i, j)

pos = nx.spring_layout(G)
nx.draw_networkx_nodes(G, pos, node_size=500, node_color='b')
nx.draw_networkx_edges(G, pos, edge_color='red', arrows=True)
nx.draw_networkx_labels(G, pos)

plt.show()
```

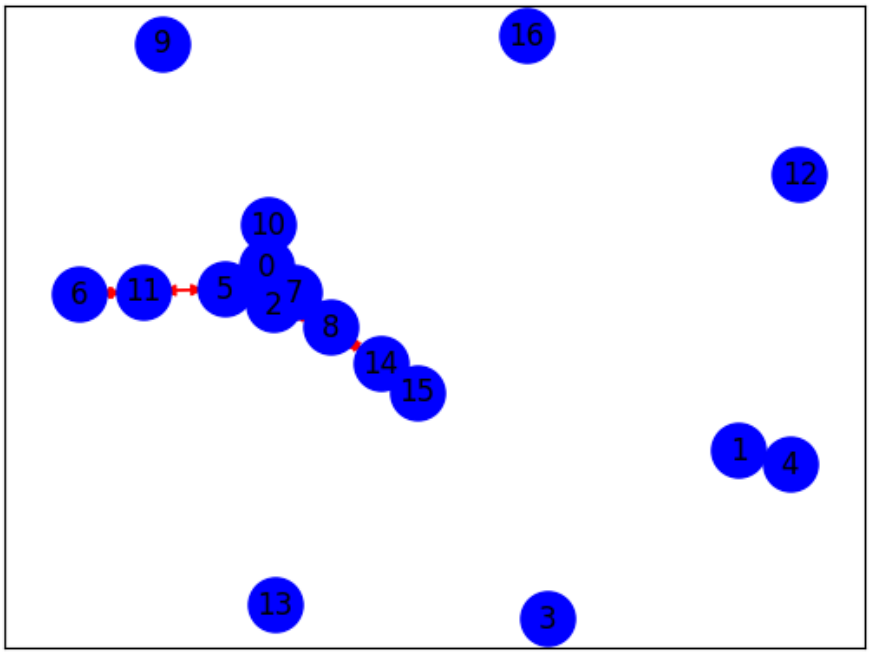

Graph Menggunakan Preprocessing

```
G_preprocessing = nx.DiGraph()
for i in range(len(cosine_preprocessing)):
    G_preprocessing.add_node(i)

for i in range(len(cosine_preprocessing)):
    for j in range(len(cosine_preprocessing)):
        similarity_preprocessing = cosine_preprocessing[i][j]
        if similarity_preprocessing > 0.1 and i != j:
            G_preprocessing.add_edge(i, j)

pos = nx.spring_layout(G)
nx.draw_networkx_nodes(G, pos, node_size=500, node_color='b')
nx.draw_networkx_edges(G, pos, edge_color='red', arrows=True)
nx.draw_networkx_labels(G, pos)

plt.show()
```

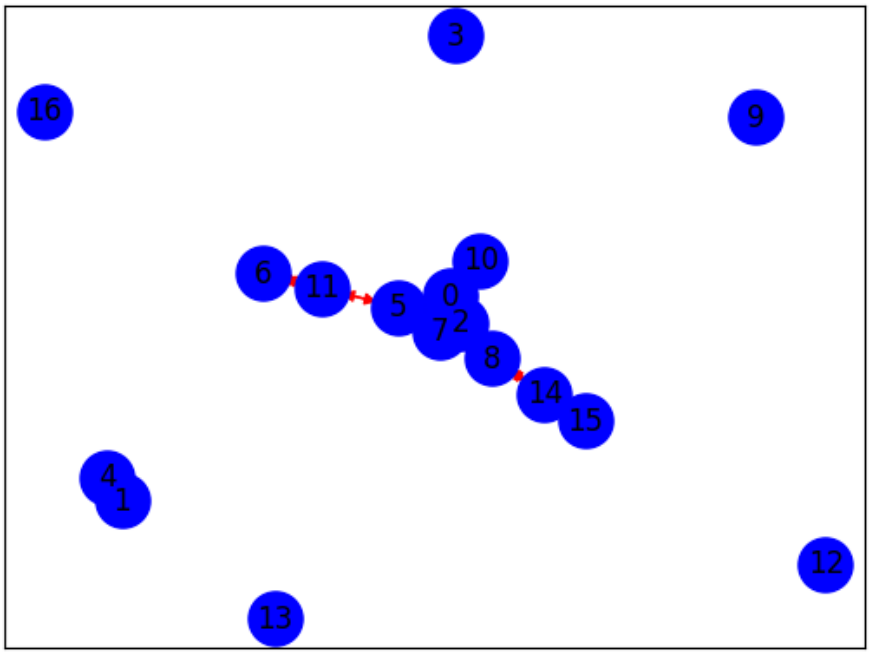
3
16
9
10
6
11
0
5
2
7
8
14
15
4
1
12
13

0

Matriks Sentralitas

Matriks Sentralitas adalah matriks yang digunakan untuk merepresentasikan ukuran sentralitas dari setiap *node* dalam jaringan. Sentralitas adalah konsep dalam analisis jaringan yang mencoba mengukur sejauh mana suatu *node* berada di pusat jaringan atau sejauh mana suatu *node* penting dalam graph. Beberapa matriks ini akan digunakan untuk membangun ringkasan dokumen yang dibuat oleh sistem, matriks ini didapatkan dari bentuk graph yang telah terbentuk pada langkah sebelumnya.

0.15 Closeness Centrality

Closeness similarity adalah ukuran sejauh mana nilai kedekatan antara pasangan node dalam suatu jaringan serupa. Dengan ini kita dapat mengukur kesamaan struktural antara node-node dalam graf berdasarkan nilai kedekatan mereka. Closeness similarity dirumuskan sebagai berikut.

$$CC(i) = \frac{N-1}{\sum_j d(i,j)}$$

Keterangan = N = nomor dari masing-masing node $d(i,j)$ = d adalah panjang jalur terpendek antara node i dan j dalam jaringan

Closeness Centrality Tanpa Preprocessing

```
closeness= nx.closeness_centrality(G)

sorted_closeness = sorted(closeness.items(), key=lambda x: x[1], reverse=True)
print("Closeness Centrality:")
for node, closeness in sorted_closeness:
    print(f"Node {node}: {closeness:.4f}")
```

```
Closeness Centrality:
Node 2: 0.3164
Node 7: 0.3164
```

```
Node 5: 0.2978
Node 0: 0.2812
Node 8: 0.2664
Node 11: 0.2201
Node 14: 0.2025
Node 10: 0.1947
Node 6: 0.1633
Node 15: 0.1534
Node 1: 0.0625
Node 4: 0.0625
Node 3: 0.0000
Node 9: 0.0000
Node 12: 0.0000
Node 13: 0.0000
Node 16: 0.0000
```

```
ringkasan_closeness = ""
print("Tiga Node Tertinggi Closeness Centrality:")
for node, closeness in sorted_closeness[:3]:
    top_sentence = kalimat[node]
    ringkasan_closeness += top_sentence + " "
    print(f"Node {node}: Closeness Centrality = {closeness:.4f}")
    print(f"Kalimat: {top_sentence}\n")
```

```
Tiga Node Tertinggi Closeness Centrality:
Node 2: Closeness Centrality = 0.3164
Kalimat: Pada saat bersamaan, Tito juga melantik Velix Vernando Wanggai sebagai Pj Gubernur Papua Pegun

Node 7: Closeness Centrality = 0.3164
Kalimat: Eks Stafsus SBY Velix Wanggai Jadi Pj Gubernur Papua Pegunungan Dia meminta Safrizal menangani

Node 5: Closeness Centrality = 0.2978
Kalimat: Tito meminta dua pj gubernur menangani kemiskinan ekstrem, inflasi, stunting, infrastruktur,
```

Closeness Centrality Menggunakan Preprocessing

```
closeness_preprocessing = nx.closeness_centrality(G_preprocessing)

sorted_closeness_preprocessing = sorted(closeness_preprocessing.items(), key=lambda x: x[1], re
print("Closeness Centrality:")
for node, closeness in sorted_closeness_preprocessing:
    print(f"Node {node}: {closeness:.4f}")
```

```
Closeness Centrality:
Node 2: 0.3375
```

```
Node 7: 0.3375
Node 8: 0.3375
Node 0: 0.3164
Node 3: 0.2664
Node 5: 0.2664
Node 11: 0.2664
Node 14: 0.2411
Node 10: 0.2109
Node 15: 0.1746
Node 1: 0.0625
Node 4: 0.0625
Node 6: 0.0000
Node 9: 0.0000
Node 12: 0.0000
Node 13: 0.0000
Node 16: 0.0000
```

```python
ringkasan_closeness_preprocessing = ""
print("Tiga Node Tertinggi Closeness Centrality Menggunakan Preprocessing:")
for node, closeness_preprocessing in sorted_closeness_preprocessing[:3]:
    top_sentence = kalimat[node]
    ringkasan_closeness_preprocessing += top_sentence + " "
    print(f"Node {node}: Closeness Centrality = {closeness_preprocessing:.4f}")
    print(f"Kalimat: {top_sentence}\n")
```

```
Tiga Node Tertinggi Closeness Centrality Menggunakan Preprocessing:
Node 2: Closeness Centrality = 0.3375
Kalimat: Pada saat bersamaan, Tito juga melantik Velix Vernando Wanggai sebagai Pj Gubernur Papua Pegun

Node 7: Closeness Centrality = 0.3375
Kalimat: Eks Stafsus SBY Velix Wanggai Jadi Pj Gubernur Papua Pegunungan Dia meminta Safrizal menangani

Node 8: Closeness Centrality = 0.3375
Kalimat: Sementara untuk Velix, tugas keamanan di Papua Pegunungan menjadi prioritas.
```

0.16 Page Rank

Dalam konteks ini, dokumen dianggap sebagai "halaman" yang terhubung oleh hubungan yang merefleksikan keterkaitan atau relevansinya. Dengan menerapkan konsep PageRank, dokumen yang dianggap lebih "penting" atau relevan dapat diberikan skor lebih tinggi. Penggunaan faktor damping, serupa dengan dalam algoritma PageRank, dapat membantu mengontrol sejauh mana

pengaruh satu dokumen terhadap yang lain. Dengan memberikan skor pada dokumen berdasarkan hubungan mereka dalam jaringan informasi, kita dapat menghasilkan ringkasan yang mencerminkan tingkat relevansi dan pentingnya masing-masing dokumen dalam konteks keseluruhan.

$$S(V_i) = (1-d) + d * \sum \frac{1}{Out(V_j)} S(V_j)$$

Keterangan = d = faktor redaman, jika tidak ada sambungan keluar in(Vi) = tautan masuk dari i, yang merupakan satu set out(Vj) = tautan keluar dari j, yang merupakan satu set |out(Vj)| = jumlah tautan keluar

Page Rank Tanpa Preprocessing

```
pagerank = nx.pagerank(G)

sorted_pagerank= sorted(pagerank.items(), key=lambda x: x[1], reverse=True)
print("Page Rank :")
for node, pagerank in sorted_pagerank:
    print(f"Node {node}: {pagerank:.4f}")
```

```
Page Rank :
Node 5: 0.1103
Node 0: 0.1102
Node 2: 0.1061
Node 7: 0.1061
Node 8: 0.0879
Node 1: 0.0784
Node 4: 0.0784
Node 14: 0.0731
Node 11: 0.0708
Node 15: 0.0428
Node 6: 0.0418
Node 10: 0.0352
Node 3: 0.0118
Node 9: 0.0118
Node 12: 0.0118
Node 13: 0.0118
Node 16: 0.0118
```

```
ringkasan_pagerank = ""
print("Tiga Node Tertinggi Page Rank :")
for node, pagerank in sorted_pagerank[:3]:
    top_sentence = kalimat[node]
    ringkasan_pagerank += top_sentence + " "
```

```
        print(f"Node {node}: Page Rank = {pagerank:.4f}")
        print(f"Kalimat: {top_sentence}\n")
```

```
Tiga Node Tertinggi Page Rank :
Node 5: Page Rank = 0.1103
Kalimat: Tito meminta dua pj gubernur menangani kemiskinan ekstrem, inflasi, stunting, infrastruktur,

Node 0: Page Rank = 0.1102
Kalimat: Menteri Dalam Negeri (Mendagri) Tito Karnavian menunjuk Safrizal ZA sebagai Penjabat (Pj) Gube

Node 2: Page Rank = 0.1061
Kalimat: Pada saat bersamaan, Tito juga melantik Velix Vernando Wanggai sebagai Pj Gubernur Papua Pegun
```

Page Rank Menggunakan Preprocessing

```
pagerank_preprocessing = nx.pagerank(G_preprocessing)

sorted_pagerank_preprocessing= sorted(pagerank_preprocessing.items(), key=lambda x: x[1], revers
print("Page Rank :")
for node, pagerank_preprocessing in sorted_pagerank_preprocessing:
    print(f"Node {node}: {pagerank_preprocessing:.4f}")
```

```
Page Rank :
Node 0: 0.1303
Node 8: 0.1102
Node 2: 0.1003
Node 7: 0.1003
Node 1: 0.0784
Node 4: 0.0784
Node 5: 0.0766
Node 14: 0.0707
Node 3: 0.0605
Node 11: 0.0596
Node 15: 0.0418
Node 10: 0.0339
Node 6: 0.0118
Node 9: 0.0118
Node 12: 0.0118
Node 13: 0.0118
Node 16: 0.0118
```

```
ringkasan_pagerank_preprocessing = ""
print("Tiga Node Tertinggi Page Rank Menggunakan Preprocessing:")
for node, pagerank_preprocessing in sorted_pagerank_preprocessing[:3]:
```

```
    top_sentence = kalimat[node]
    ringkasan_pagerank_preprocessing += top_sentence + " "
    print(f"Node {node}: Page Rank = {pagerank_preprocessing:.4f}")
    print(f"Kalimat: {top_sentence}\n")
```

```
Tiga Node Tertinggi Page Rank Menggunakan Preprocessing:
Node 0: Page Rank = 0.1303
Kalimat: Menteri Dalam Negeri (Mendagri) Tito Karnavian menunjuk Safrizal ZA sebagai Penjabat (Pj) Gube

Node 8: Page Rank = 0.1102
Kalimat: Sementara untuk Velix, tugas keamanan di Papua Pegunungan menjadi prioritas.

Node 2: Page Rank = 0.1003
Kalimat: Pada saat bersamaan, Tito juga melantik Velix Vernando Wanggai sebagai Pj Gubernur Papua Pegun
```

0.17 Eigen Vector

Dalam ringkasan dokumen, eigenvector tidak digunakan secara langsung untuk menghitung ringkasan. Namun, Anda dapat memanfaatkan konsep pengukuran penting dari eigenvector untuk memberikan bobot atau skor pada elemen-elemen dalam dokumen yang mungkin memiliki kepentingan lebih besar dalam rangka membuat ringkasan. Perhitungan eigenvector yang didapatkan dari matriks korelasi untuk menentukan bobot relatif setiap dokumen atau kata. Berikut merupakan rumus untuk menghitung nilai eigenvector.

$$det(\lambda.I - A)$$

Keterangan = det( ) = Merupakan fungsi determinan, yang menghasilkan nilai determinan dari suatu matriks. = Merupakan simbol yang mewakili eigenvalue yang sedang dicari. I = Merupakan matriks identitas yang sesuai dengan dimensi matriks. A = Merupakan matriks yang eigenvalues-nya ingin dicari.

Eigen Vector Tanpa Preprocessing

```
eigenvector = nx.eigenvector_centrality(G)

sorted_eigenvector= sorted(eigenvector.items(), key=lambda x: x[1], reverse=True)
print("Eigen Vector :")
for node, eigenvector in sorted_eigenvector:
    print(f"Node {node}: {eigenvector:.4f}")
```

```
Eigen Vector :
```

```
Node 2: 0.4823
Node 7: 0.4823
Node 5: 0.4453
Node 0: 0.4426
Node 8: 0.3053
Node 11: 0.1398
Node 10: 0.1274
Node 14: 0.0958
Node 6: 0.0402
Node 15: 0.0276
Node 1: 0.0000
Node 4: 0.0000
Node 3: 0.0000
Node 9: 0.0000
Node 12: 0.0000
Node 13: 0.0000
Node 16: 0.0000
```

```
ringkasan_eigenvector = ""
print("Tiga Node Tertinggi Eigen Vector:")
for node, eigenvector in sorted_eigenvector[:3]:
    top_sentence = kalimat[node]
    ringkasan_eigenvector += top_sentence + " "
    print(f"Node {node}: Page Rank = {eigenvector:.4f}")
    print(f"Kalimat: {top_sentence}\n")
```

```
Tiga Node Tertinggi Eigen Vector:
Node 2: Page Rank = 0.4823
Kalimat: Pada saat bersamaan, Tito juga melantik Velix Vernando Wanggai sebagai Pj Gubernur Papua Pegun

Node 7: Page Rank = 0.4823
Kalimat: Eks Stafsus SBY Velix Wanggai Jadi Pj Gubernur Papua Pegunungan Dia meminta Safrizal menangani

Node 5: Page Rank = 0.4453
Kalimat: Tito meminta dua pj gubernur menangani kemiskinan ekstrem, inflasi, stunting, infrastruktur,
```

```
eigenvector_preprocessing = nx.eigenvector_centrality(G_preprocessing)

sorted_eigenvector_preprocessing= sorted(eigenvector_preprocessing.items(), key=lambda x: x[1],
print("Eigen Vector :")
for node, eigenvector_preprocessing in sorted_eigenvector_preprocessing:
    print(f"Node {node}: {eigenvector_preprocessing:.4f}")
```

```
Eigen Vector :
```

```
Node 2: 0.4692
Node 7: 0.4692
Node 0: 0.4619
Node 5: 0.3956
Node 8: 0.3344
Node 11: 0.1708
Node 3: 0.1427
Node 10: 0.1305
Node 14: 0.1027
Node 15: 0.0290
Node 1: 0.0000
Node 4: 0.0000
Node 6: 0.0000
Node 9: 0.0000
Node 12: 0.0000
Node 13: 0.0000
Node 16: 0.0000
```

```
ringkasan_eigenvector_preprocessing = ""
print("Tiga Node Tertinggi Eigen Vector Menggunakan Preprocessing:")
for node, eigenvector_preprocessing in sorted_eigenvector_preprocessing[:3]:
    top_sentence = kalimat[node]
    ringkasan_eigenvector_preprocessing += top_sentence + " "
    print(f"Node {node}: Page Rank = {eigenvector_preprocessing:.4f}")
    print(f"Kalimat: {top_sentence}\n")
```

```
Tiga Node Tertinggi Eigen Vector Menggunakan Preprocessing:
Node 2: Page Rank = 0.4692
Kalimat: Pada saat bersamaan, Tito juga melantik Velix Vernando Wanggai sebagai Pj Gubernur Papua Pegun

Node 7: Page Rank = 0.4692
Kalimat: Eks Stafsus SBY Velix Wanggai Jadi Pj Gubernur Papua Pegunungan Dia meminta Safrizal menangani

Node 0: Page Rank = 0.4619
Kalimat: Menteri Dalam Negeri (Mendagri) Tito Karnavian menunjuk Safrizal ZA sebagai Penjabat (Pj) Gube
```

0

Evaluasi

ROUGE (*Recall-Oriented Understudy for Gisting Evaluation*) adalah sekelompok metrik evaluasi otomatis yang umum digunakan untuk mengukur kualitas ringkasan teks. ROUGE memiliki beberapa varian, dan di antaranya, ROUGE-1, ROUGE-2, dan ROUGE-L merupakan metrik yang sering digunakan untuk mengukur sejauh mana kedekatan ringkasan sistem dengan ringkasan referensi.

```
#referensi ringkasan yang dibuat secara manual
referensi = ['Menteri Dalam Negeri Tito Karnavian melantik Safrizal ZA sebagai Penjabat Gubernu
```

```
print(referensi)
```

```
['Menteri Dalam Negeri Tito Karnavian melantik Safrizal ZA sebagai Penjabat Gubernur Bangka Belitung da
```

```
def rouge(referensi, hasil_ringkasan):
    rouge = Rouge()
    scores = rouge.get_scores(hasil_ringkasan, referensi)
    print (scores)
```

0.18 Closeness Centrality

```
rouge(referensi[0], ringkasan_closeness)
```

```
[{'rouge-1': {'r': 0.3333333333333333, 'p': 0.5641025641025641, 'f': 0.41904761437823135}, 'rouge-2':
```

```
rouge(referensi[0], ringkasan_closeness_preprocessing)
```

```
[{'rouge-1': {'r': 0.22727272727272727, 'p': 0.42857142857142855, 'f': 0.2970296984413293}, 'rouge-2'
```

Berikut adalah hasil simpulan berdasarkan evaluasi ROUGE pada *Closeness Centrality*:

Berdasarkan evaluasi ROUGE *closeness centrality*, ditemukan bahwa tanpa menggunakan preprocessing, sistem ringkasan cenderung mencapai hasil yang lebih baik. Secara khusus, pada metrik ROUGE-1, sistem tanpa preprocessing memiliki recall sekitar 0.33, precision sekitar 0.56, dan F1-Score sekitar 0.42. Sebaliknya, ketika menggunakan preprocessing, nilai recall turun menjadi sekitar 0.23, precision sekitar 0.43, dan F1-Score sekitar 0.30.

0.19 Page Rank

```
rouge(referensi[0], ringkasan_pagerank)
```

```
[{'rouge-1': {'r': 0.4090909090909091, 'p': 0.675, 'f': 0.5094339575649698}, 'rouge-2': {'r': 0.24324
```

```
rouge(referensi[0], ringkasan_pagerank_preprocessing)
```

```
[{'rouge-1': {'r': 0.30303030303030304, 'p': 0.5714285714285714, 'f': 0.39603959943142836}, 'rouge-2'
```

Berdasarkan hasil evaluasi ROUGE pada *Page Rank* untuk ringkasan dengan dan tanpa preprocessing menggunakan metode *Page Rank*, dapat disimpulkan bahwa tanpa preprocessing sistem mampu mencapai hasil yang lebih baik dalam sebagian besar metrik evaluasi. Pada metrik ROUGE-1, sistem tanpa preprocessing memiliki nilai recall sekitar 0.41, precision sekitar 0.675, dan F1-Score sekitar 0.51. Sementara itu, dengan preprocessing, nilai recall turun menjadi sekitar 0.30, precision sekitar 0.571, dan F1-Score sekitar 0.40

0.20 Eigen Vector

```
rouge(referensi[0], ringkasan_eigenvector)
```

```
[{'rouge-1': {'r': 0.3333333333333333, 'p': 0.5641025641025641, 'f': 0.41904761437823135}, 'rouge-2':
```

```
rouge(referensi[0], ringkasan_eigenvector_preprocessing)
```

```
[{'rouge-1': {'r': 0.30303030303030304, 'p': 0.5405405405405406, 'f': 0.3883495099594685}, 'rouge-2':
```

Berdasarkan hasil evaluasi ROUGE untuk ringkasan dengan dan tanpa preprocessing menggunakan metode eigenvector centrality, dapat ditarik beberapa kesimpulan. Tanpa preprocessing, sistem cenderung mencapai hasil yang sedikit lebih baik pada sebagian besar metrik evaluasi. Pada metrik ROUGE-1, sistem tanpa preprocessing memiliki nilai recall sekitar 0.33, precision sekitar 0.56, dan F1-Score sekitar 0.42. Sementara itu, dengan preprocessing, nilai recall dan F1-Score tetap stabil, sedangkan precision mengalami penurunan menjadi sekitar 0.54.

0

Mencari Kata Kunci Berita

Aplikasi untuk mencari kata kunci berita Berita Ringkas[3]

[3] https://syayidalaziz-berita-ringkas.hf.space/

0

Instalasi

```
import pandas as pd
import nltk
import re
from nltk.tokenize import word_tokenize
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.metrics.pairwise import cosine_similarity
from nltk.tokenize import word_tokenize
from nltk.corpus import stopwords
import networkx as nx
import matplotlib.pyplot as plt
from collections import Counter
```

```
nltk.download('punkt')
nltk.download("stopwords")
```

```
[nltk_data] Downloading package punkt to /root/nltk_data...
[nltk_data]   Package punkt is already up-to-date!
[nltk_data] Downloading package stopwords to /root/nltk_data...
[nltk_data]   Package stopwords is already up-to-date!
```

```
True
```

0

Data

Data yang digunakan menggunakan hasil crawling data pada website CNN Indonesia dalam kategori berita nasional.

```
from google.colab import drive
drive.mount('/content/drive')

csv_path = '/content/drive/My Drive/Task/Pencarian dan Penambangan Web/Tugas 2/data/berita-cnn.
df = pd.read_csv(csv_path)
df
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/dr
```

	judul	berita
0	Dirjen Kemendagri Safrizal ZA Jadi Pj Gubernur...	Menteri Dalam Negeri (Mendagri) Tito Karn
1	Ganjar Temui Gus Mus di Rembang, Bahas Polemi...	Bakal capres PDIP Ganjar Pranowo mengun
2	Nomor Urut Capres-Cawapres Diundi KPU Besok	Komisi Pemilihan Umum (KPU) RI bakal m
3	Utut Adianto Pimpin Panja Netralitas TNI di Pe...	Komisi I DPR sudah menyepakati pembentu
4	Istri Cak Nur Curhat ke Gus Mus: Nepotisme Dip...	Sejumlah tokoh bangsa yang mengatasnamak
5	Eks Stafsus SBY Velix Wanggai Jadi Pj Gubernur...	Presiden Joko Widodo menunjuk mantan Sta
6	KPU Resmi Tetapkan Prabowo, Ganjar, Anies seb...	Komisi Pemilihan Umum (KPU) resmi mene
7	Eks Kadis PUPR Papua Didakwa Terima Suap & Gr...	Kepala Dinas Pekerjaan Umum dan Perumah
8	Fatia Maulidiyanti Dituntut 3,5 Tahun Penjara...	Aktivitis Hak Asasi Manusia (HAM) Fatia M
9	KPK Panggil Keponakan SYL Istri Kapolrestabes ...	Komisi Pemberantasan Korupsi (KPK) mem
10	Haris Azhar Dituntut 4 Tahun Penjara Kasus Lor...	Aktivitis Hak Asasi Manusia (HAM) Haris A
11	KPK Dalami Dugaan Kartu Anggota Kasino SYL	Komisi Pemberantasan Korupsi (KPK) tenga
12	Pelecehan Anggota BEM UNY Hoaks, Polisi Tangk...	Polisi memastikan dugaan kasus pelecehan m
13	Dinkes DKI: Kasus Cacar Monyet di Jakarta Capa...	Dinas Kesehatan (Dinkes) DKI Jakarta mela
14	Pemkab Ungkap Susun 6 Dimensi pada Perencanaan...	Kabupaten Klaten menyatakan memiliki ena
15	Sri Mulyani Sebut Petugas Kesehatan Merupakan ...	Pemerintah Kabupaten Klaten menggelar Up
16	Klaten Ambil Bagian pada Evaluasi Tahap II Sma...	Kabupaten Klaten turut ambil bagian sebaga
17	Puncak Peringatan HKN Ke-59, Bupati Klaten Ap...	Bupati Klaten, Jawa Tengah, Sri Mulyani, m
18	Nakes Klaten Diminta Jadi Pelopor Budaya Hidup...	Bupati Klaten, Sri Mulyani, meminta tenaga
19	FOTO: Suhartoyo Resmi Jadi Ketua MK Gantikan A...	Hakim konstitusi Suhartoyo resmi dilantik se
20	Fit and Proper Test Panglima TNI Singgung Isu ...	Calon Panglima TNI Jenderal Agus Subiyant
21	Kapolda Metro Sebut Tersangka Kasus Pemerasan ...	Kapolda Metro Jaya Irjen Karyoto menyebut

	judul	berita
22	Irjen Karyoto soal Firli: Kita Lihat Saja Beso...	Kapolda Metro Jaya Irjen Karyoto angkat su
23	Suhartoyo Janji Segera Bentuk MKMK Permanen	Ketua Mahkamah Konstitusi (MK) Suhartoy
24	Mahfud Singgung Menteri Jokowi Ditangkap Korup...	Menko Polhukam Mahfud MD menyinggung
25	Mahfud Respons Dugaan Saling Sandera KPK-Polda...	Menko Polhukam Mahfud MD angkat suara
26	Agus Subiyanto di DPR: Jika Ingin Damai, Bers...	Kepala Staf Angkatan Darat (KSAD) sekalig
27	OTT KPK di Sorong Terkait Pengondisian Temuan ...	Komisi Pemberantasan Korupsi (KPK) meng
28	KPK Total Tangkap 5 Orang Terkait OTT di Sorong	Komisi Pemberantasan Korupsi (KPK) total
29	Anwar Usman Absen di Pelantikan Ketua MK, Izi...	Hakim Konstitusi Anwar Usman tidak hadir
30	KPK Total Tangkap 5 Orang Terkait OTT di Sorong	Komisi Pemberantasan Korupsi (KPK) total
31	Anwar Usman Absen di Pelantikan Ketua MK, Izi...	Hakim Konstitusi Anwar Usman tidak hadir
32	Komisi I DPR Sepakati Agus Subiyanto Jadi Pang...	Komisi I DPR secara resmi menyepakati KS
33	Jelang Penetapan Capres-Cawapres, Jalan Depan...	Jalan Imam Bonjol depan kantor Komisi Pe
34	Massa Atribut Serba Hitam Demo di KPU Jelang P...	Demonstrasi terjadi di depan kantor Komisi
35	PAN Solid Dukung Prabowo-Gibran dan Menang Pil...	Wakil Bendahara Umum Partai Amanat Nas
36	LHKPN Ketua MK Suhartoyo, Punya Harta Rp14,7 ...	Ketua Mahkamah Konstitusi (MK) terpilih p
37	Fit & Proper Test, Agus Janji Ingatkan Prajur...	Calon Panglima TNI Jenderal Agus Subiyant
38	Yasonna soal Wamenkumham Jadi Tersangka: Silak...	Menteri Hukum dan Hak Asasi Manusia (Me
39	Ketua MK Suhartoyo Menangis Saat Pidato Soal K...	Hakim Mahkamah Konstitusi (MK) Suhartoy
40	Bahlil Heran Gibran Dipersoalkan: Banyak Mente...	Ketua Dewan Pembina Relawan Pengusaha I
41	Gibran: Laporkan Saja ke Bawaslu Jika Ada Kecu...	Wali Kota Solo sekaligus bakal cawapres Gib
42	Bupati Dhito: Batik Kediri Siap Masuk Kancah N...	Bupati Kediri Hanindhito Himawan Pramana
43	Sempat Macet Parah, Jalan Mampang Prapatan Ar...	Kemacetan sempat terjadi di Jalan Mampang
44	Pejabat Sorong dan Pegawai BPK Terjaring OTT KPK	Komisi Pemberantasan Korupsi (KPK) mela
45	Fit and Proper Test Calon Panglima TNI, Jende...	Kepala Staf Angkatan Darat (KSAD) sekalig
46	VIDEO: Momen Suhartoyo Resmi Dilantik Jadi Ket...	Mahkamah Konstitusi resmi melantik Suhart
47	Wali Kota Semarang Ingin Masyarakat Tak Bergan...	Festival pangan pendamping beras bertajuk
48	Panglima TNI-Kapolri ke Rumah Agus Subiyanto J...	Panglima TNI Laksamana Yudo Margono da
49	Suhartoyo Resmi Jadi Ketua MK Gantikan Anwar U...	Hakim konstitusi Suhartoyo resmi dilantik se

```
berita = df['berita'].iloc[18]
berita
```

```
'Bupati Klaten, Sri Mulyani, meminta tenaga kesehatan (nakes) di Kabupaten Klaten berperan aktif dalam
```

0

Preprocessing

Pada analisis kata kunci berita kali ini akan membutuhkan proses preprocessing untuk menghilangkan beberapa karakter yang tidak digunkanan dalam membuat kata kunci berita ini. Tahapan preprocessing ini antara lain yaitu menghapus angka, simbol dan stopword pada berita.

```
def preprocessing(text):
    text = re.sub(r'\d+', '', text)
    text = re.sub(r'[^\w\s.]', '', text)
    text = text.lower()

    stop_words = set(stopwords.words('indonesian'))
    words = text.split()
    filtered_words = [word for word in words if word.lower() not in stop_words]

    preprocessing_text = ' '.join(filtered_words)

    return preprocessing_text
```

```
berita = preprocessing(berita)
print(berita)
```

```
bupati klaten sri mulyani tenaga kesehatan nakes kabupaten klaten berperan aktif meningkatkan kesadara
```

0

Membentuk Matriks

0.21 Memisahkan Kalimat

```
kalimat = nltk.sent_tokenize(berita)
kalimat = [sentence.replace('.', '') for sentence in kalimat]
print(kalimat)
```

```
['bupati klaten sri mulyani tenaga kesehatan nakes kabupaten klaten berperan aktif meningkatkan kesada
```

0.22 Memisahkan Kata

```
kata = word_tokenize(berita)
kata = [k.lower() for k in kata if k != '.']
kata = list(set(kata))
print(kata)
```

```
['berperan', 'kesehatan', 'transformasi', 'kali', 'dukungan', 'taraf', 'memiliki', 'pengobatan', 'maj
```

0.23 Matriks Kata dalam Berita

```
matrikskata = pd.DataFrame(0, index=kata, columns=kata)
```

```
for sent in kalimat:
    kata_kalimat = word_tokenize(sent)
    for i in range(len(kata_kalimat)-1):
```

```
        matrikskata.at[kata_kalimat[i], kata_kalimat[i+1]] += 1 # jika kata pada sebelah kanan
        matrikskata.at[kata_kalimat[i+1], kata_kalimat[i]] += 1 # jika kata pada sebelah kiri
```

```
matrikskata
```

	berperan	kesehatan	transformasi	kali	dukungan	taraf	memiliki	pengobatan	maj
berperan	0	0	0	0	0	0	0	0	0
kesehatan	0	0	1	0	0	1	0	0	0
transformasi	0	1	0	0	0	0	0	0	0
kali	0	0	0	0	0	0	0	0	0
dukungan	0	0	0	0	0	0	0	0	0
...	...	...	...	...	...	...	...	...	...
sri	0	1	0	0	0	0	0	1	0
meningkatkan	0	0	0	0	0	1	0	0	0
mengangkat	0	0	0	0	0	0	0	0	0
fokus	0	0	0	0	0	0	0	0	0
lantaran	0	1	0	0	0	0	0	0	0

0

Membentuk Graph

0.24 Cosine Similarity

Cosine similarity digunakan untuk mengukur seberapa mirip dua vektor dalam ruang berdimensi banyak. Hasil dari *cosine similarity* ini akan menentukan apakah vektor tersebut menuju ke arah yang sama. Semakin kecil sudut antara dua vektor, maka semakin mirip satu sama lain sedangkan begitu juga sebaliknya, semakin besar nilai *cosine similarity* maka vektor tersebut dianggap jauh kemiripannya. Dalam ringkasan dokumen ini penting untuk menghitung nilai *cosine similarity* untuk mengetahui hubungan kesamaan antara kalimat satu dengan kalimat lainnya. Vektor yang digunakan untuk menghitung nilai *cosine simmilarity* ini adalah hasil dari TF-IDF pada langkah sebelumnya. Berikut merupakan rumus yang digunakan untuk menghitung nilai *cosine simmilarity*.

$$simmilarity(A, B) = \frac{A \cdot B}{|A||B|}$$

Keterangan = A.B = Vector dot product dari A dan B dihitung dengan $\sum_{i=1}^{n} x_k y_k$ |A| = Panjang vektor A dihitung dengan $\sum_{i=1}^{n} x_k^2$ |B| = Panjang vektor A dihitung dengan $\sum_{i=1}^{n} y_k^2$

```
cosine = cosine_similarity(matrikskata, matrikskata)
```

```
similarity = pd.DataFrame(cosine, columns=matrikskata.index, index=matrikskata.index)
similarity
```

	berperan	kesehatan	transformasi	kali	dukungan	taraf	memiliki	pengobatan
berperan	1.000000	0.314970	0.000000	0.0	0.353553	0.000000	0.000000	0.000000
kesehatan	0.314970	1.000000	0.000000	0.0	0.534522	0.000000	0.178174	0.178174
transformasi	0.000000	0.000000	1.000000	0.0	0.000000	0.500000	0.000000	0.000000
kali	0.000000	0.000000	0.000000	1.0	0.000000	0.000000	0.000000	0.000000
dukungan	0.353553	0.534522	0.000000	0.0	1.000000	0.000000	0.000000	0.000000
...	...	...	...	...	...	...	...	...
sri	0.213201	0.000000	0.150756	0.0	0.000000	0.150756	0.000000	0.000000

	berperan	kesehatan	transformasi	kali	dukungan	taraf	memiliki	pengobatan
meningkatkan	0.250000	0.062994	0.000000	0.0	0.000000	0.000000	0.000000	0.000000
mengangkat	0.353553	0.000000	0.500000	0.0	0.000000	0.000000	0.000000	0.000000
fokus	0.000000	0.267261	0.000000	0.0	0.000000	0.000000	0.500000	0.000000
lantaran	0.000000	0.000000	0.707107	0.0	0.000000	0.707107	0.000000	0.000000

0.25 Graph

Hasil dari nilai *cosine simmilarity* ini akan dapat digunakan untuk membentuk graph dengan menggunakan modul nx.graph. Graph ini akan menggambarkan ilustrasi dari kedekatan setiap kalimatnya dalam berita tersebut. Dalam proses penggambaran graph tersebut diperlukan ambang batas (*treshold*) yang digunakan untuk memberikan batasan agar keseluruhan kalimatnya tidak dihubungkan menggunakan garis *(edge)*. Nilai ambang batas (*treshold*) yang digunakan akan mempengaruhi graph yang digambarkan

```
G = nx.DiGraph()
for i in range(len(cosine)):
    G.add_node(i)

for i in range(len(cosine)):
    for j in range(len(cosine)):
        similarity = cosine[i][j]
        if similarity > 0.1 and i != j:
            G.add_edge(i, j)

pos = nx.spring_layout(G)
nx.draw_networkx_nodes(G, pos, node_size=500, node_color='b')
nx.draw_networkx_edges(G, pos, edge_color='red', arrows=True)
nx.draw_networkx_labels(G, pos)

plt.show()
```

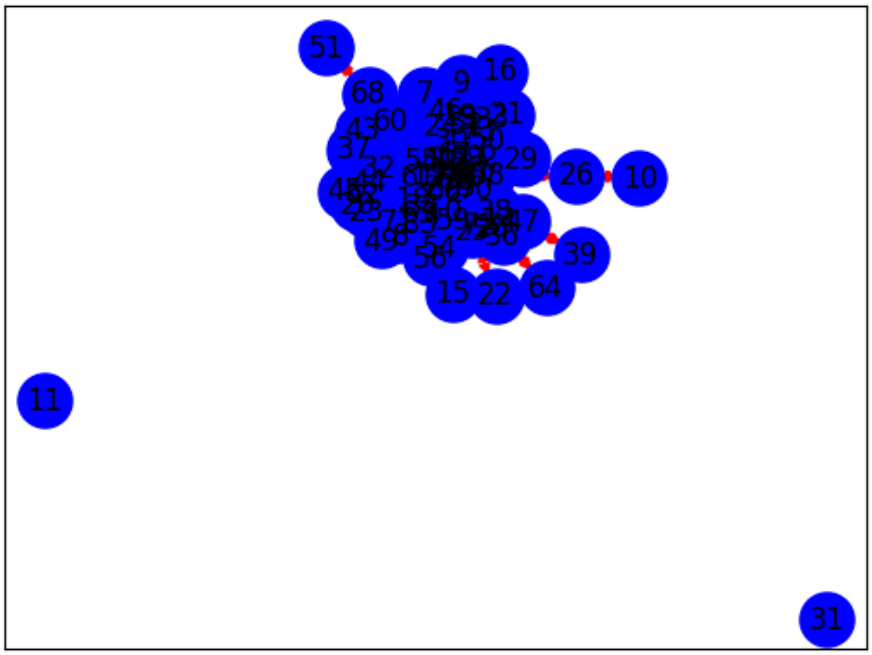
51
16
9
7
68
21
60
43
37
29
26
10
39
64
22
15
11
31

0

Hasil Kata Kunci

0.26 Page Rank

Dalam konteks ini, dokumen dianggap sebagai "halaman" yang terhubung oleh hubungan yang merefleksikan keterkaitan atau relevansinya. Dengan menerapkan konsep PageRank, dokumen yang dianggap lebih "penting" atau relevan dapat diberikan skor lebih tinggi. Penggunaan faktor damping, serupa dengan dalam algoritma PageRank, dapat membantu mengontrol sejauh mana pengaruh satu dokumen terhadap yang lain. Dengan memberikan skor pada dokumen berdasarkan hubungan mereka dalam jaringan informasi, kita dapat menghasilkan ringkasan yang mencerminkan tingkat relevansi dan pentingnya masing-masing dokumen dalam konteks keseluruhan.

$$S(V_i) = (1-d) + d * \sum \frac{1}{Out(V_j)} S(V_j)$$

Keterangan = d = faktor redaman, jika tidak ada sambungan keluar in(Vi) = tautan masuk dari i, yang merupakan satu set out(Vj) = tautan keluar dari j, yang merupakan satu set |out(Vj)| = jumlah tautan keluar

```
pagerank = nx.pagerank(G)

sorted_pagerank= sorted(pagerank.items(), key=lambda x: x[1], reverse=True)
print("Page Rank :")
for node, pagerank in sorted_pagerank:
    print(f"Node {node}: {pagerank:.4f}")
```

```
Page Rank :
Node 57: 0.0373
Node 1: 0.0341
Node 13: 0.0321
Node 70: 0.0292
Node 27: 0.0292
Node 66: 0.0292
Node 40: 0.0273
Node 61: 0.0267
```

```
Node 17: 0.0258
Node 5: 0.0243
Node 0: 0.0237
Node 69: 0.0228
Node 48: 0.0226
Node 2: 0.0225
Node 67: 0.0215
Node 42: 0.0212
Node 35: 0.0208
Node 65: 0.0196
Node 74: 0.0196
Node 12: 0.0196
Node 41: 0.0196
Node 59: 0.0195
Node 19: 0.0182
Node 33: 0.0172
Node 18: 0.0167
Node 25: 0.0149
Node 36: 0.0133
Node 72: 0.0132
Node 6: 0.0126
Node 4: 0.0123
Node 34: 0.0123
Node 63: 0.0123
Node 30: 0.0110
Node 49: 0.0108
Node 58: 0.0107
Node 20: 0.0106
Node 14: 0.0105
Node 28: 0.0105
Node 23: 0.0103
Node 44: 0.0102
Node 52: 0.0098
Node 53: 0.0098
Node 73: 0.0098
Node 3: 0.0094
Node 47: 0.0092
Node 68: 0.0092
Node 60: 0.0090
Node 46: 0.0090
Node 50: 0.0083
Node 56: 0.0082
Node 71: 0.0080
Node 8: 0.0078
Node 26: 0.0076
```

```
Node 45: 0.0075
Node 55: 0.0073
Node 32: 0.0071
Node 7: 0.0064
Node 24: 0.0062
Node 38: 0.0062
Node 54: 0.0060
Node 21: 0.0056
Node 29: 0.0054
Node 10: 0.0053
Node 16: 0.0052
Node 43: 0.0050
Node 62: 0.0048
Node 51: 0.0046
Node 9: 0.0046
Node 39: 0.0040
Node 64: 0.0035
Node 22: 0.0035
Node 15: 0.0033
Node 37: 0.0031
Node 11: 0.0020
Node 31: 0.0020
```

```
print("Tiga Node Tertinggi Page Rank :")
sentence = ""
for node, pagerank in sorted_pagerank[:3]:
  top_sentence = kata[node]
  sentence += top_sentence + ", "
  print(f"Node {node}: Page Rank = {pagerank:.4f}")
  print(f"Kalimat: {top_sentence}")
```

```
Tiga Node Tertinggi Page Rank :
Node 57: Page Rank = 0.0373
Kalimat: kabupaten
Node 1: Page Rank = 0.0341
Kalimat: kesehatan
Node 13: Page Rank = 0.0321
Kalimat: masyarakat
```

0.27 Kata Kunci Berita

```
news = df['berita'].iloc[18]
print('Berita yang digunakan : ')
news
```

```
Berita yang digunakan :
'Bupati Klaten, Sri Mulyani, meminta tenaga kesehatan (nakes) di Kabupaten Klaten berperan aktif dalam
```

```
print('Kata Kunci :', sentence)
```

```
Kata Kunci : kabupaten, kesehatan, masyarakat,
```

0

News Classification

Aplikasi untuk klasifikasi berita News Classification[4]

[4] https://syayidalaziz-news-classification.hf.space/

0

Instalisasi

```
!pip install nltk
!pip install Sastrawi
!pip install joblib
```

```
Requirement already satisfied: nltk in /usr/local/lib/python3.10/dist-packages (3.8.1)
Requirement already satisfied: click in /usr/local/lib/python3.10/dist-packages (from nltk) (8.1.7)
Requirement already satisfied: joblib in /usr/local/lib/python3.10/dist-packages (from nltk) (1.3.2)
Requirement already satisfied: regex>=2021.8.3 in /usr/local/lib/python3.10/dist-packages (from nltk)
Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-packages (from nltk) (4.66.1)
Requirement already satisfied: Sastrawi in /usr/local/lib/python3.10/dist-packages (1.0.1)
Requirement already satisfied: joblib in /usr/local/lib/python3.10/dist-packages (1.3.2)
```

```
import pandas as pd
import nltk
import re
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from nltk.corpus import stopwords
from Sastrawi.Stemmer.StemmerFactory import StemmerFactory
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import ConfusionMatrixDisplay, confusion_matrix, accuracy_score
import joblib
```

```
nltk.download("punkt")
nltk.download("stopwords")
```

```
[nltk_data] Downloading package punkt to /root/nltk_data...
[nltk_data]   Unzipping tokenizers/punkt.zip.
[nltk_data] Downloading package stopwords to /root/nltk_data...
[nltk_data]   Unzipping corpora/stopwords.zip.
```

```
True
```

0

Data

```
from google.colab import drive
drive.mount('/content/drive')

csv_path = '/content/drive/My Drive/Task/Pencarian dan Penambangan Web/Ujian Akhir/data/berita-
df = pd.read_csv(csv_path)
df.head()
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/dr
```

	judul	berita
0	Minyak Jatuh ke Harga Terendah 6 Bulan Imbas L...	Harga minyak turun ke level terendah dalam en
1	Janji Ekonomi Anies, Prabowo hingga Ganjar Jik...	Daftar Isi Anies-Cak Imin 2. Prabowo-Gibran 3
2	Pemerintah Bakal Kirim 'Surat Cinta' ke Bank y...	Pemerintah bakal mengirimkan surat teguran k
3	PNS Langgar Aturan Karena Terima KUR	Kementerian Koperasi dan UKM (Kemenkop U
4	Geng Konglomerat Aguan, Prajogo Pengestu Cs Ku...	Sejumlah konglomerat kenamaan Indonesia berk

```
df['label'].value_counts()
```

```
edukasi     300
olahraga    296
ekonomi     294
hiburan     293
Name: label, dtype: int64
```

```
berita = df["berita"].astype(str)
```

```
berita
```

```
0       Harga minyak turun ke level terendah dalam ena...
1       Daftar Isi Anies-Cak Imin 2. Prabowo-Gibran 3....
2       Pemerintah bakal mengirimkan surat teguran kep...
3       Kementerian Koperasi dan UKM (Kemenkop UKM) me...
```

```
4       Sejumlah konglomerat kenamaan Indonesia berkum...
                              ...
1178    Klasemen Liga Voli Putri Korea Selatan atau V-...
1179    Borneo FC bermain imbang tanpa gol melawan Bar...
1180    Buriram, CNN Indonesia Pembalap Indonesia Andi...
1181    Red Sparks yang diperkuat pemain Timnas Voli P...
1182    Pemain asal Indonesia, Pratama Arhan sangat mi...
Name: berita, Length: 1183, dtype: object
```

0

Preprocessing

0.28 Lowercase

```
preprocessing = berita.str.lower()
```

0.29 Tokenisasi

```
def process_tokenize(text):
    text = text.split()
    return text
```

```
preprocessing = preprocessing.apply(process_tokenize)
preprocessing
```

```
0       [harga, minyak, turun, ke, level, terendah, da...
1       [daftar, isi, anies-cak, imin, 2., prabowo-gib...
2       [pemerintah, bakal, mengirimkan, surat, tegura...
3       [kementerian, koperasi, dan, ukm, (kemenkop, u...
4       [sejumlah, konglomerat, kenamaan, indonesia, b...
                              ...
1178    [klasemen, liga, voli, putri, korea, selatan, ...
1179    [borneo, fc, bermain, imbang, tanpa, gol, mela...
1180    [buriram,, cnn, indonesia, pembalap, indonesia...
1181    [red, sparks, yang, diperkuat, pemain, timnas,...
1182    [pemain, asal, indonesia,, pratama, arhan, san...
Name: berita, Length: 1183, dtype: object
```

0.30 Process Punctuation

```
def process_punctuation(tokens):
    cleaned_tokens = [re.sub(r'[.,()&=%:-]', '', token) for token in tokens]
    cleaned_tokens = [re.sub(r'\d+', '', token) for token in cleaned_tokens]

    return cleaned_tokens
```

```
preprocessing = preprocessing.apply(process_punctuation)
preprocessing
```

```
0       [harga, minyak, turun, ke, level, terendah, da...
1       [daftar, isi, aniescak, imin, , prabowogibran,...
2       [pemerintah, bakal, mengirimkan, surat, tegura...
3       [kementerian, koperasi, dan, ukm, kemenkop, uk...
4       [sejumlah, konglomerat, kenamaan, indonesia, b...
                              ...
1178    [klasemen, liga, voli, putri, korea, selatan, ...
1179    [borneo, fc, bermain, imbang, tanpa, gol, mela...
1180    [buriram, cnn, indonesia, pembalap, indonesia,...
1181    [red, sparks, yang, diperkuat, pemain, timnas,...
1182    [pemain, asal, indonesia, pratama, arhan, sang...
Name: berita, Length: 1183, dtype: object
```

0.31 Stopword

```
def process_stopword_token(tokens):
    stop_words = set(stopwords.words("indonesian"))
    # custom_stop_words = ['masingmasing','tiaptiap','satusatunya', 'intinya', 'seiring']
    # stop_words.update(custom_stop_words)
    filtered_tokens = [token for token in tokens if token.lower() not in stop_words]
    return " ".join(filtered_tokens)
```

```
preprocessing = preprocessing.apply(process_stopword_token)
preprocessing
```

```
0       harga minyak turun level terendah enam kamis /...
```

```
1       daftar isi aniescak imin  prabowogibran  ganja...
2       pemerintah mengirimkan surat teguran bankbank ...
3       kementerian koperasi ukm kemenkop ukm pegawai ...
4       konglomerat kenamaan indonesia berkumpul memba...
                              ...
1178    klasemen liga voli putri korea selatan vleague...
1179    borneo fc bermain imbang gol melawan barito pu...
1180    buriram cnn indonesia pembalap indonesia andi ...
1181    red sparks diperkuat pemain timnas voli putri ...
1182    pemain indonesia pratama arhan minim terlibat ...
Name: berita, Length: 1183, dtype: object
```

0.32 Steeming

```
factory = StemmerFactory()
stemmer = factory.create_stemmer()
```

```
preprocessing = preprocessing.apply(lambda text:stemmer.stem(text))
preprocessing
```

```
df['preprocessing-berita'] = preprocessing
df.to_csv('/content/drive/My Drive/Task/Pencarian dan Penambangan Web/Ujian Akhir/data/preproces
```

0

Feature Extraction

```
csv_preprocessing = '/content/drive/My Drive/Task/Pencarian dan Penambangan Web/Ujian Akhir/dat
data = pd.read_csv(csv_preprocessing)
data
```

	judul	berita
0	Minyak Jatuh ke Harga Terendah 6 Bulan Imbas L...	Harga minyak turun ke level terendah dalam
1	Janji Ekonomi Anies, Prabowo hingga Ganjar Jik...	Daftar Isi Anies-Cak Imin 2. Prabowo-Gibra
2	Pemerintah Bakal Kirim 'Surat Cinta' ke Bank y...	Pemerintah bakal mengirimkan surat tegura
3	PNS Langgar Aturan Karena Terima KUR	Kementerian Koperasi dan UKM (Kemenko
4	Geng Konglomerat Aguan, Prajogo Pengestu Cs Ku...	Sejumlah konglomerat kenamaan Indonesia
...	...	...
1178	Klasemen Liga Voli Korea Usai Megawati dan Red...	Klasemen Liga Voli Putri Korea Selatan ata
1179	Hasil Liga 1: Borneo FC Ditahan Imbang, Persib...	Borneo FC bermain imbang tanpa gol melaw
1180	Hasil ARRC: Balapan Diinvestigasi, Andi Gilang...	Buriram, CNN Indonesia Pembalap Indonesi
1181	Megawati dan Red Sparks Kalah Dramatis dari IB...	Red Sparks yang diperkuat pemain Timnas
1182	Rapor Pratama Arhan Usai Tokyo Verdy Promosi k...	Pemain asal Indonesia, Pratama Arhan sang

```
preprocessing_berita = data["preprocessing-berita"]
```

0.33 TF-IDF

```
tfidfvectorizer = TfidfVectorizer(analyzer='word')
tfidf = tfidfvectorizer.fit_transform(preprocessing_berita)
tfidf_token = tfidfvectorizer.get_feature_names_out()
```

```
tfidf_df = pd.DataFrame(data = tfidf.toarray(), columns = tfidf_token)
tfidf_df
```

	aa	aaa	aaaa	aaaaaaahhhhh	aadaanaa	aadamu	aadunaa	aafaati	aafaita	aafihim	...	zu
0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
1	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
2	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
4	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
...	...	...	...	...	...	...	...	...	...	...	...	...
1178	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
1179	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
1180	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
1181	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
1182	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0

0

Split Data

```
X = tfidf_df
y = df['label']

y.head()
```

```
0    ekonomi
1    ekonomi
2    ekonomi
3    ekonomi
4    ekonomi
Name: label, dtype: object
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

```
X_train.head()
```

	aa	aaa	aaaa	aaaaaaahhhhh	aadaanaa	aadamu	aadunaa	aafaati	aafaita	aafihim	...	zul
650	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
977	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
993	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
730	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
275	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0

0

Classification

0.34 KNN

```
knn_classifier = KNeighborsClassifier(n_neighbors=5)
knn_classifier.fit(X_train, y_train)
y_pred = knn_classifier.predict(X_test)
```

```
cm = confusion_matrix(y_test, y_pred)
disp = ConfusionMatrixDisplay(confusion_matrix=cm)
accuracy = accuracy_score(y_test, y_pred)

plt.figure(figsize=(4, 3))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')

plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title(f'Confusion Matrix for')
plt.show()

print('Accuracy =', accuracy)
```

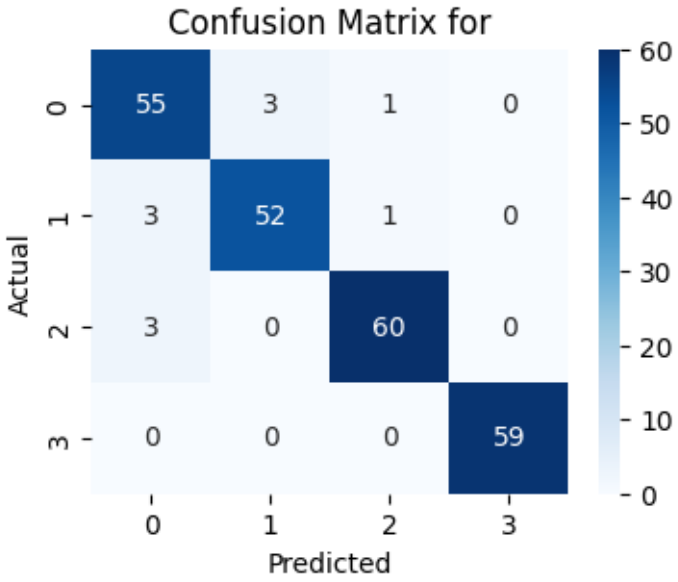


```
Accuracy = 0.9535864978902954
```

0.35 Naive Bayes

```
naive_bayes_classifier = MultinomialNB()
naive_bayes_classifier.fit(X_train, y_train)
y_pred_naivebayes = naive_bayes_classifier.predict(X_test)
```

```
cm_naivebayes = confusion_matrix(y_test, y_pred_naivebayes)
disp = ConfusionMatrixDisplay(confusion_matrix=cm_naivebayes)
accuracy = accuracy_score(y_test, y_pred)

plt.figure(figsize=(4, 3))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')

plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title(f'Confusion Matrix for')
plt.show()
```

```
print('Accuracy =', accuracy)
```

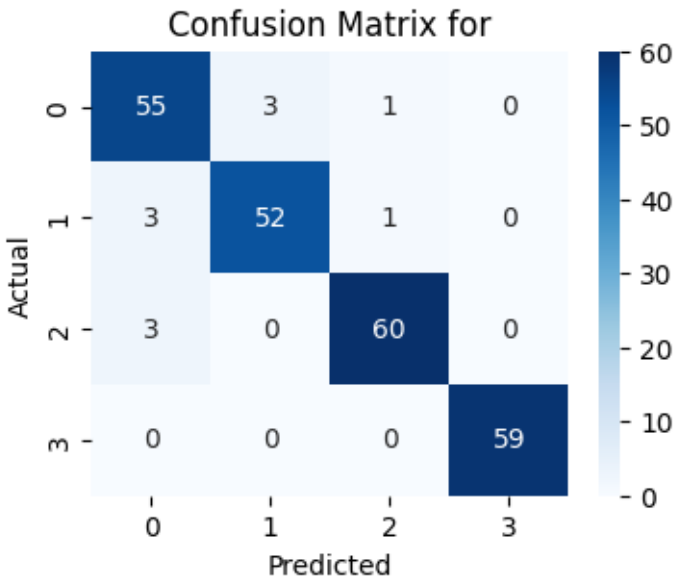


```
Accuracy = 0.9535864978902954
```

0

Save Model

```
joblib.dump(tfidfvectorizer, 'tfidf_vectorizer')
```

```
['tfidf_vectorizer']
```

```
joblib.dump(naive_bayes_classifier, 'nb_model')
```

```
['nb_model']
```